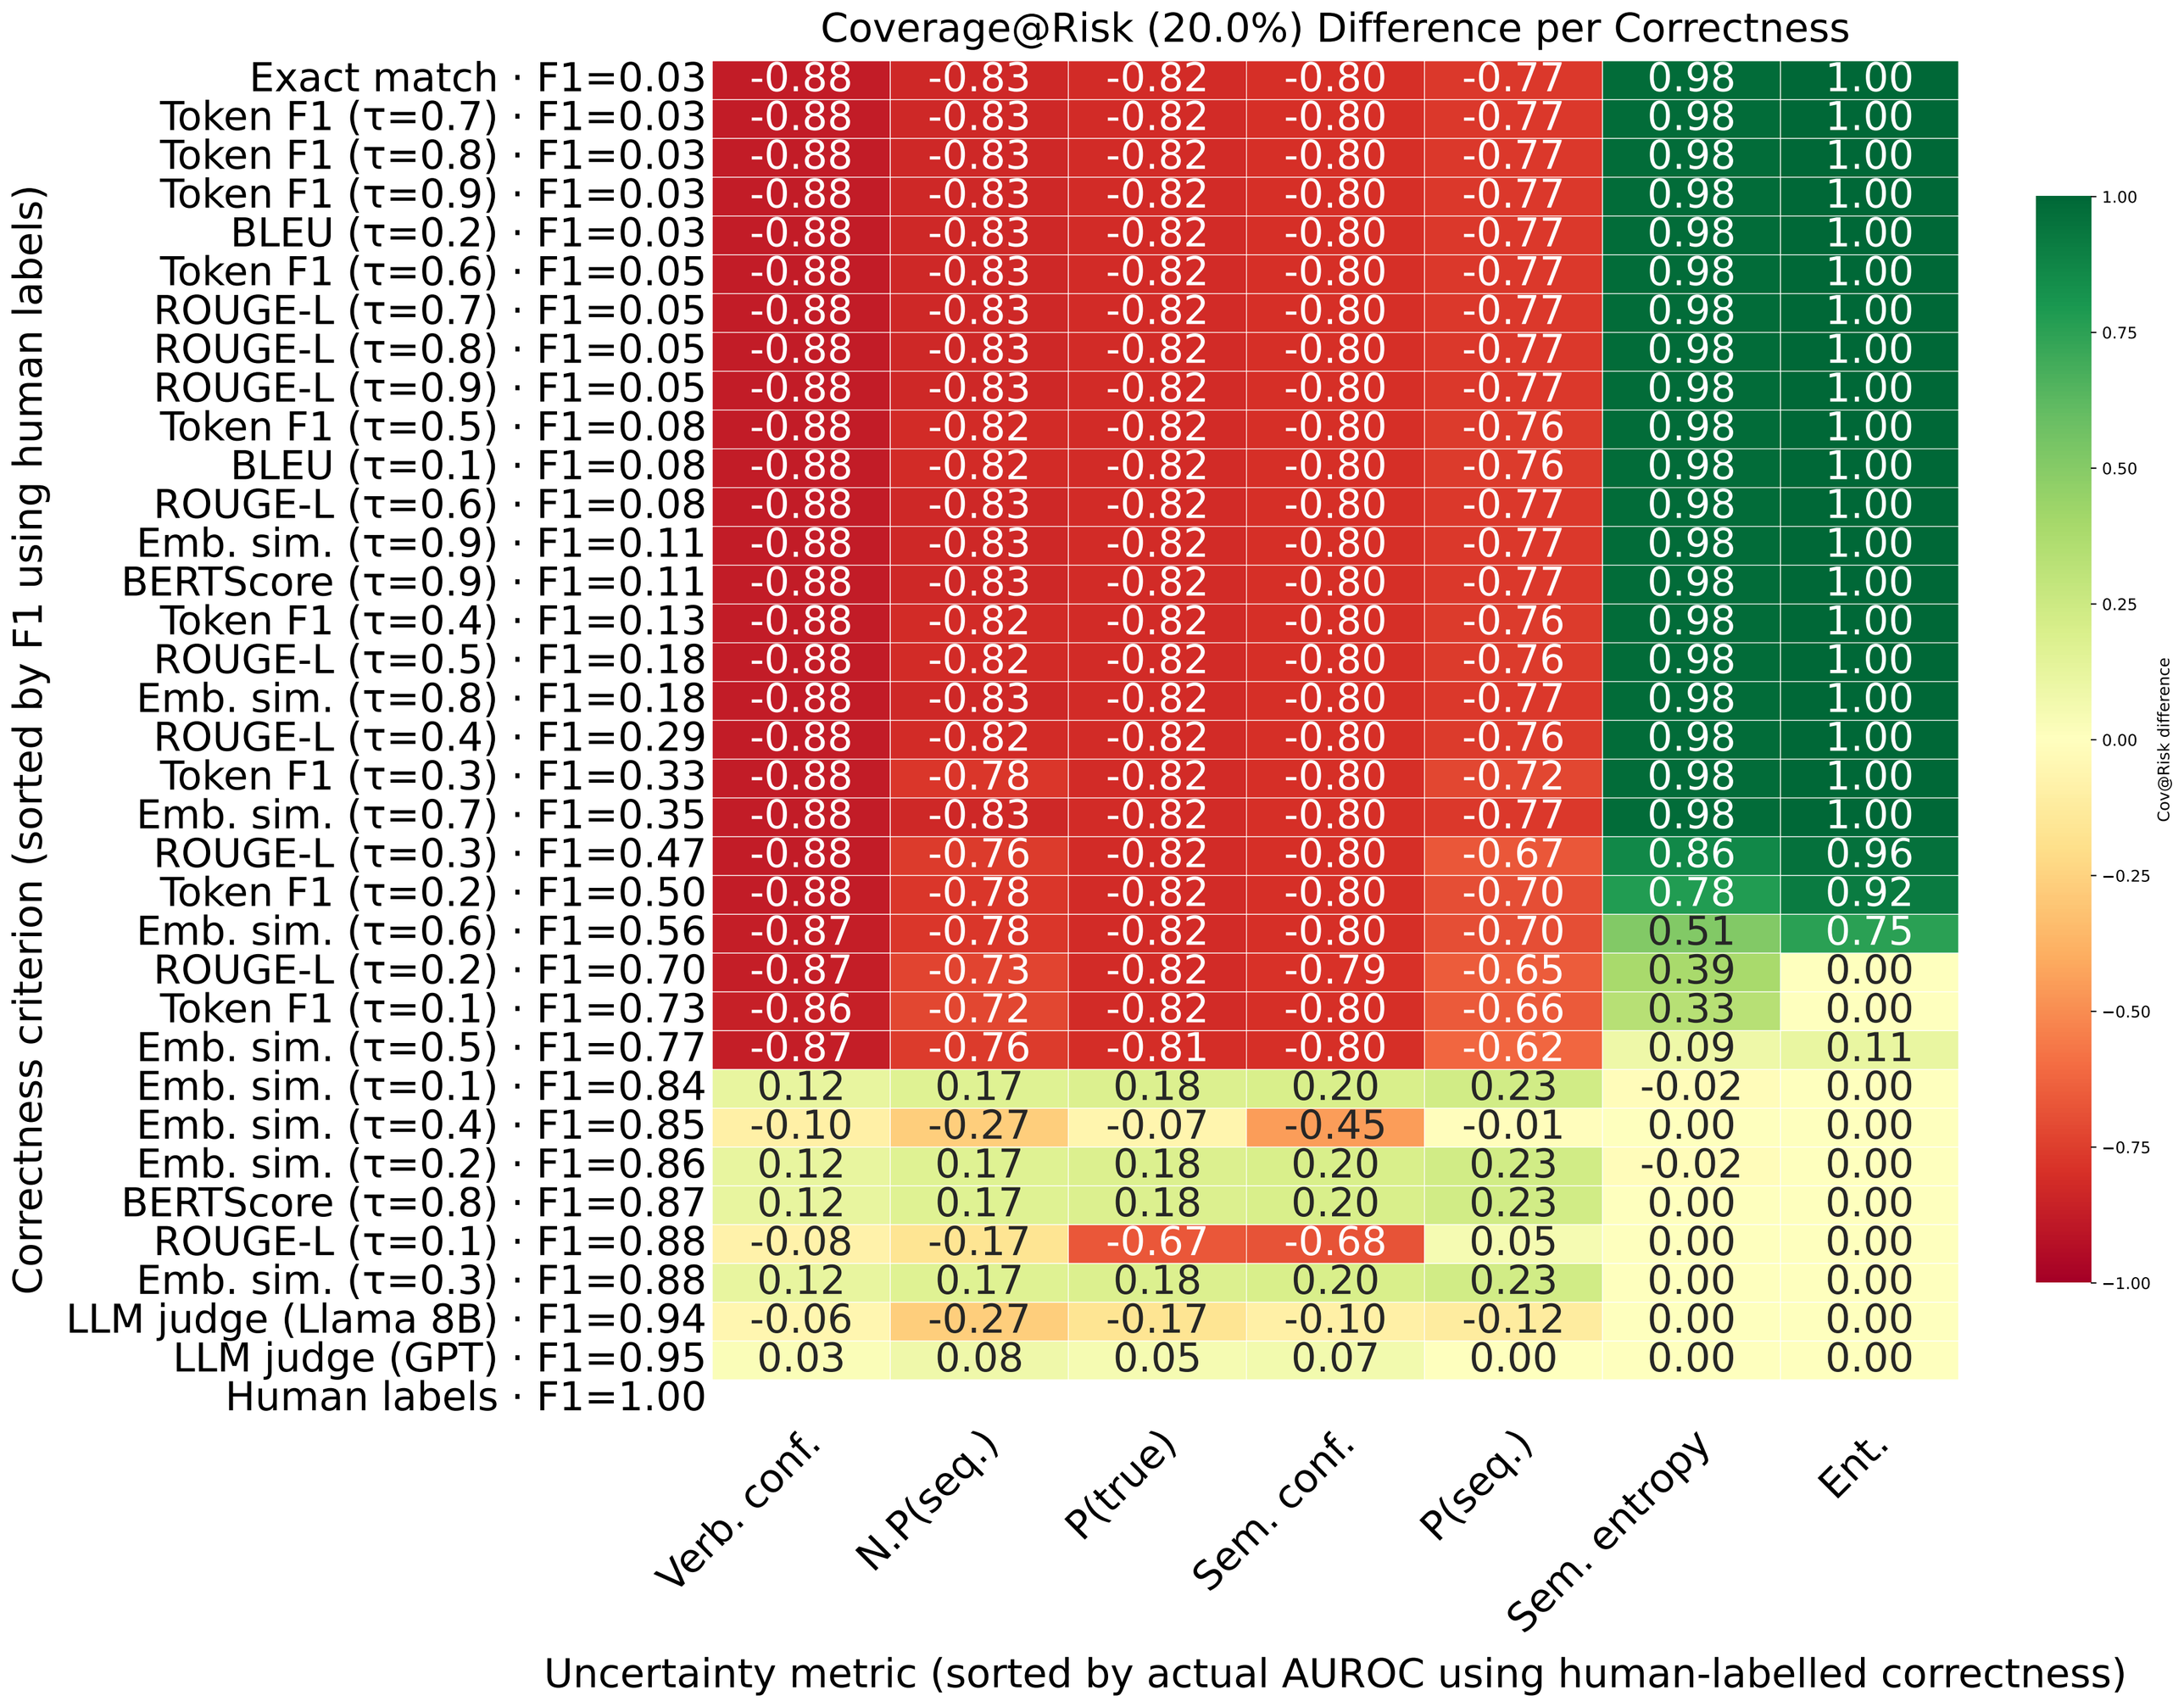
Coverage@Risk (20.0%) Difference per Correctness
Correctness criterion (sorted by F1 using human labels)
Uncertainty metric (sorted by actual AUROC using human-labelled correctness)
Cov@Risk difference
1.00
0.75
0.50
0.25
0.00
−0.25
−0.50
−0.75
−1.00
Verb. conf.
N.P(seq.)
P(true)
Sem. conf.
P(seq.)
Sem. entropy
Ent.
Exact match · F1=0.03 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.7) · F1=0.03 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.8) · F1=0.03 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.9) · F1=0.03 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
BLEU (τ=0.2) · F1=0.03 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.6) · F1=0.05 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
ROUGE-L (τ=0.7) · F1=0.05 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
ROUGE-L (τ=0.8) · F1=0.05 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
ROUGE-L (τ=0.9) · F1=0.05 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.5) · F1=0.08 -0.88 -0.82 -0.82 -0.80 -0.76 0.98 1.00
BLEU (τ=0.1) · F1=0.08 -0.88 -0.82 -0.82 -0.80 -0.76 0.98 1.00
ROUGE-L (τ=0.6) · F1=0.08 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Emb. sim. (τ=0.9) · F1=0.11 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
BERTScore (τ=0.9) · F1=0.11 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
Token F1 (τ=0.4) · F1=0.13 -0.88 -0.82 -0.82 -0.80 -0.76 0.98 1.00
ROUGE-L (τ=0.5) · F1=0.18 -0.88 -0.82 -0.82 -0.80 -0.76 0.98 1.00
Emb. sim. (τ=0.8) · F1=0.18 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
ROUGE-L (τ=0.4) · F1=0.29 -0.88 -0.82 -0.82 -0.80 -0.76 0.98 1.00
Token F1 (τ=0.3) · F1=0.33 -0.88 -0.78 -0.82 -0.80 -0.72 0.98 1.00
Emb. sim. (τ=0.7) · F1=0.35 -0.88 -0.83 -0.82 -0.80 -0.77 0.98 1.00
ROUGE-L (τ=0.3) · F1=0.47 -0.88 -0.76 -0.82 -0.80 -0.67 0.86 0.96
Token F1 (τ=0.2) · F1=0.50 -0.88 -0.78 -0.82 -0.80 -0.70 0.78 0.92
Emb. sim. (τ=0.6) · F1=0.56 -0.87 -0.78 -0.82 -0.80 -0.70 0.51 0.75
ROUGE-L (τ=0.2) · F1=0.70 -0.87 -0.73 -0.82 -0.79 -0.65 0.39 0.00
Token F1 (τ=0.1) · F1=0.73 -0.86 -0.72 -0.82 -0.80 -0.66 0.33 0.00
Emb. sim. (τ=0.5) · F1=0.77 -0.87 -0.76 -0.81 -0.80 -0.62 0.09 0.11
Emb. sim. (τ=0.1) · F1=0.84 0.12 0.17 0.18 0.20 0.23 -0.02 0.00
Emb. sim. (τ=0.4) · F1=0.85 -0.10 -0.27 -0.07 -0.45 -0.01 0.00 0.00
Emb. sim. (τ=0.2) · F1=0.86 0.12 0.17 0.18 0.20 0.23 -0.02 0.00
BERTScore (τ=0.8) · F1=0.87 0.12 0.17 0.18 0.20 0.23 0.00 0.00
ROUGE-L (τ=0.1) · F1=0.88 -0.08 -0.17 -0.67 -0.68 0.05 0.00 0.00
Emb. sim. (τ=0.3) · F1=0.88 0.12 0.17 0.18 0.20 0.23 0.00 0.00
LLM judge (Llama 8B) · F1=0.94 -0.06 -0.27 -0.17 -0.10 -0.12 0.00 0.00
LLM judge (GPT) · F1=0.95 0.03 0.08 0.05 0.07 0.00 0.00 0.00
Human labels · F1=1.00