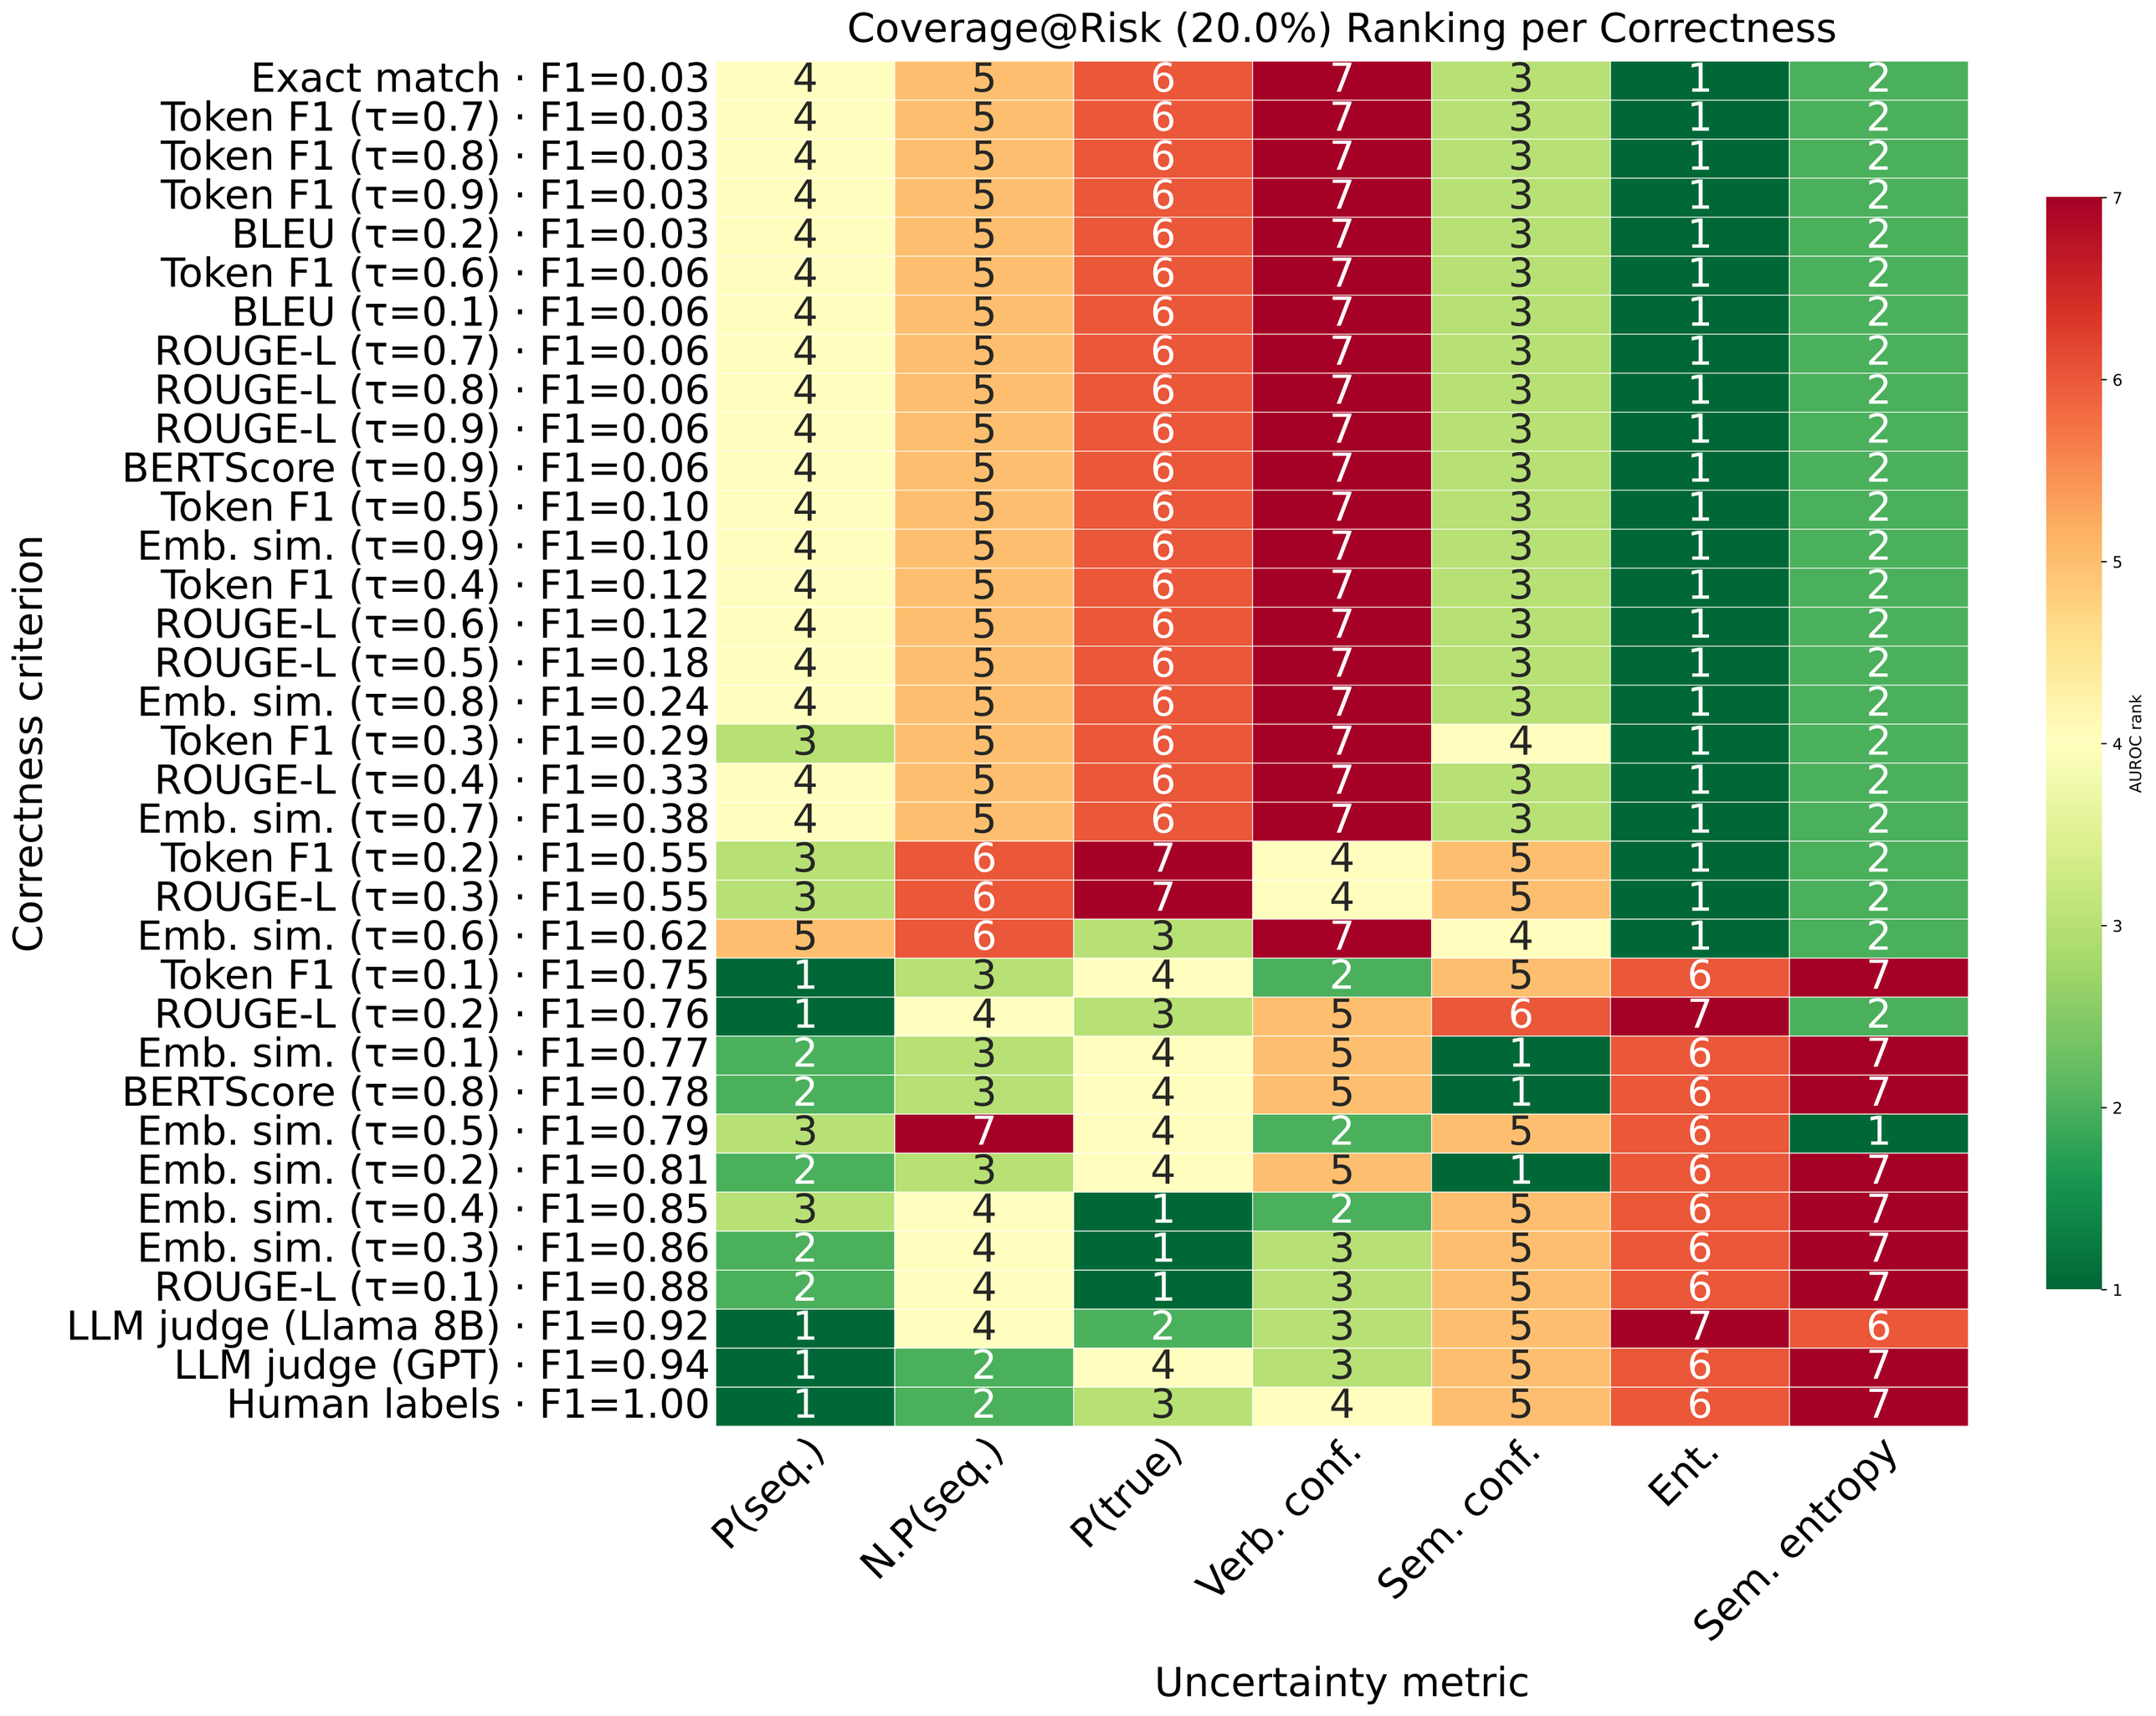
Coverage@Risk (20.0%) Ranking per Correctness
Correctness criterion
Uncertainty metric
AUROC rank
Exact match · F1=0.03 4 5 6 7 3 1 2
Token F1 (τ=0.7) · F1=0.03 4 5 6 7 3 1 2
Token F1 (τ=0.8) · F1=0.03 4 5 6 7 3 1 2
Token F1 (τ=0.9) · F1=0.03 4 5 6 7 3 1 2
BLEU (τ=0.2) · F1=0.03 4 5 6 7 3 1 2
Token F1 (τ=0.6) · F1=0.06 4 5 6 7 3 1 2
BLEU (τ=0.1) · F1=0.06 4 5 6 7 3 1 2
ROUGE-L (τ=0.7) · F1=0.06 4 5 6 7 3 1 2
ROUGE-L (τ=0.8) · F1=0.06 4 5 6 7 3 1 2
ROUGE-L (τ=0.9) · F1=0.06 4 5 6 7 3 1 2
BERTScore (τ=0.9) · F1=0.06 4 5 6 7 3 1 2
Token F1 (τ=0.5) · F1=0.10 4 5 6 7 3 1 2
Emb. sim. (τ=0.9) · F1=0.10 4 5 6 7 3 1 2
Token F1 (τ=0.4) · F1=0.12 4 5 6 7 3 1 2
ROUGE-L (τ=0.6) · F1=0.12 4 5 6 7 3 1 2
ROUGE-L (τ=0.5) · F1=0.18 4 5 6 7 3 1 2
Emb. sim. (τ=0.8) · F1=0.24 4 5 6 7 3 1 2
Token F1 (τ=0.3) · F1=0.29 3 5 6 7 4 1 2
ROUGE-L (τ=0.4) · F1=0.33 4 5 6 7 3 1 2
Emb. sim. (τ=0.7) · F1=0.38 4 5 6 7 3 1 2
Token F1 (τ=0.2) · F1=0.55 3 6 7 4 5 1 2
ROUGE-L (τ=0.3) · F1=0.55 3 6 7 4 5 1 2
Emb. sim. (τ=0.6) · F1=0.62 5 6 3 7 4 1 2
Token F1 (τ=0.1) · F1=0.75 1 3 4 2 5 6 7
ROUGE-L (τ=0.2) · F1=0.76 1 4 3 5 6 7 2
Emb. sim. (τ=0.1) · F1=0.77 2 3 4 5 1 6 7
BERTScore (τ=0.8) · F1=0.78 2 3 4 5 1 6 7
Emb. sim. (τ=0.5) · F1=0.79 3 7 4 2 5 6 1
Emb. sim. (τ=0.2) · F1=0.81 2 3 4 5 1 6 7
Emb. sim. (τ=0.4) · F1=0.85 3 4 1 2 5 6 7
Emb. sim. (τ=0.3) · F1=0.86 2 4 1 3 5 6 7
ROUGE-L (τ=0.1) · F1=0.88 2 4 1 3 5 6 7
LLM judge (Llama 8B) · F1=0.92 1 4 2 3 5 7 6
LLM judge (GPT) · F1=0.94 1 2 4 3 5 6 7
Human labels · F1=1.00 1 2 3 4 5 6 7
P(seq.)
N.P(seq.)
P(true)
Verb. conf.
Sem. conf.
Ent.
Sem. entropy
1
2
3
4
5
6
7