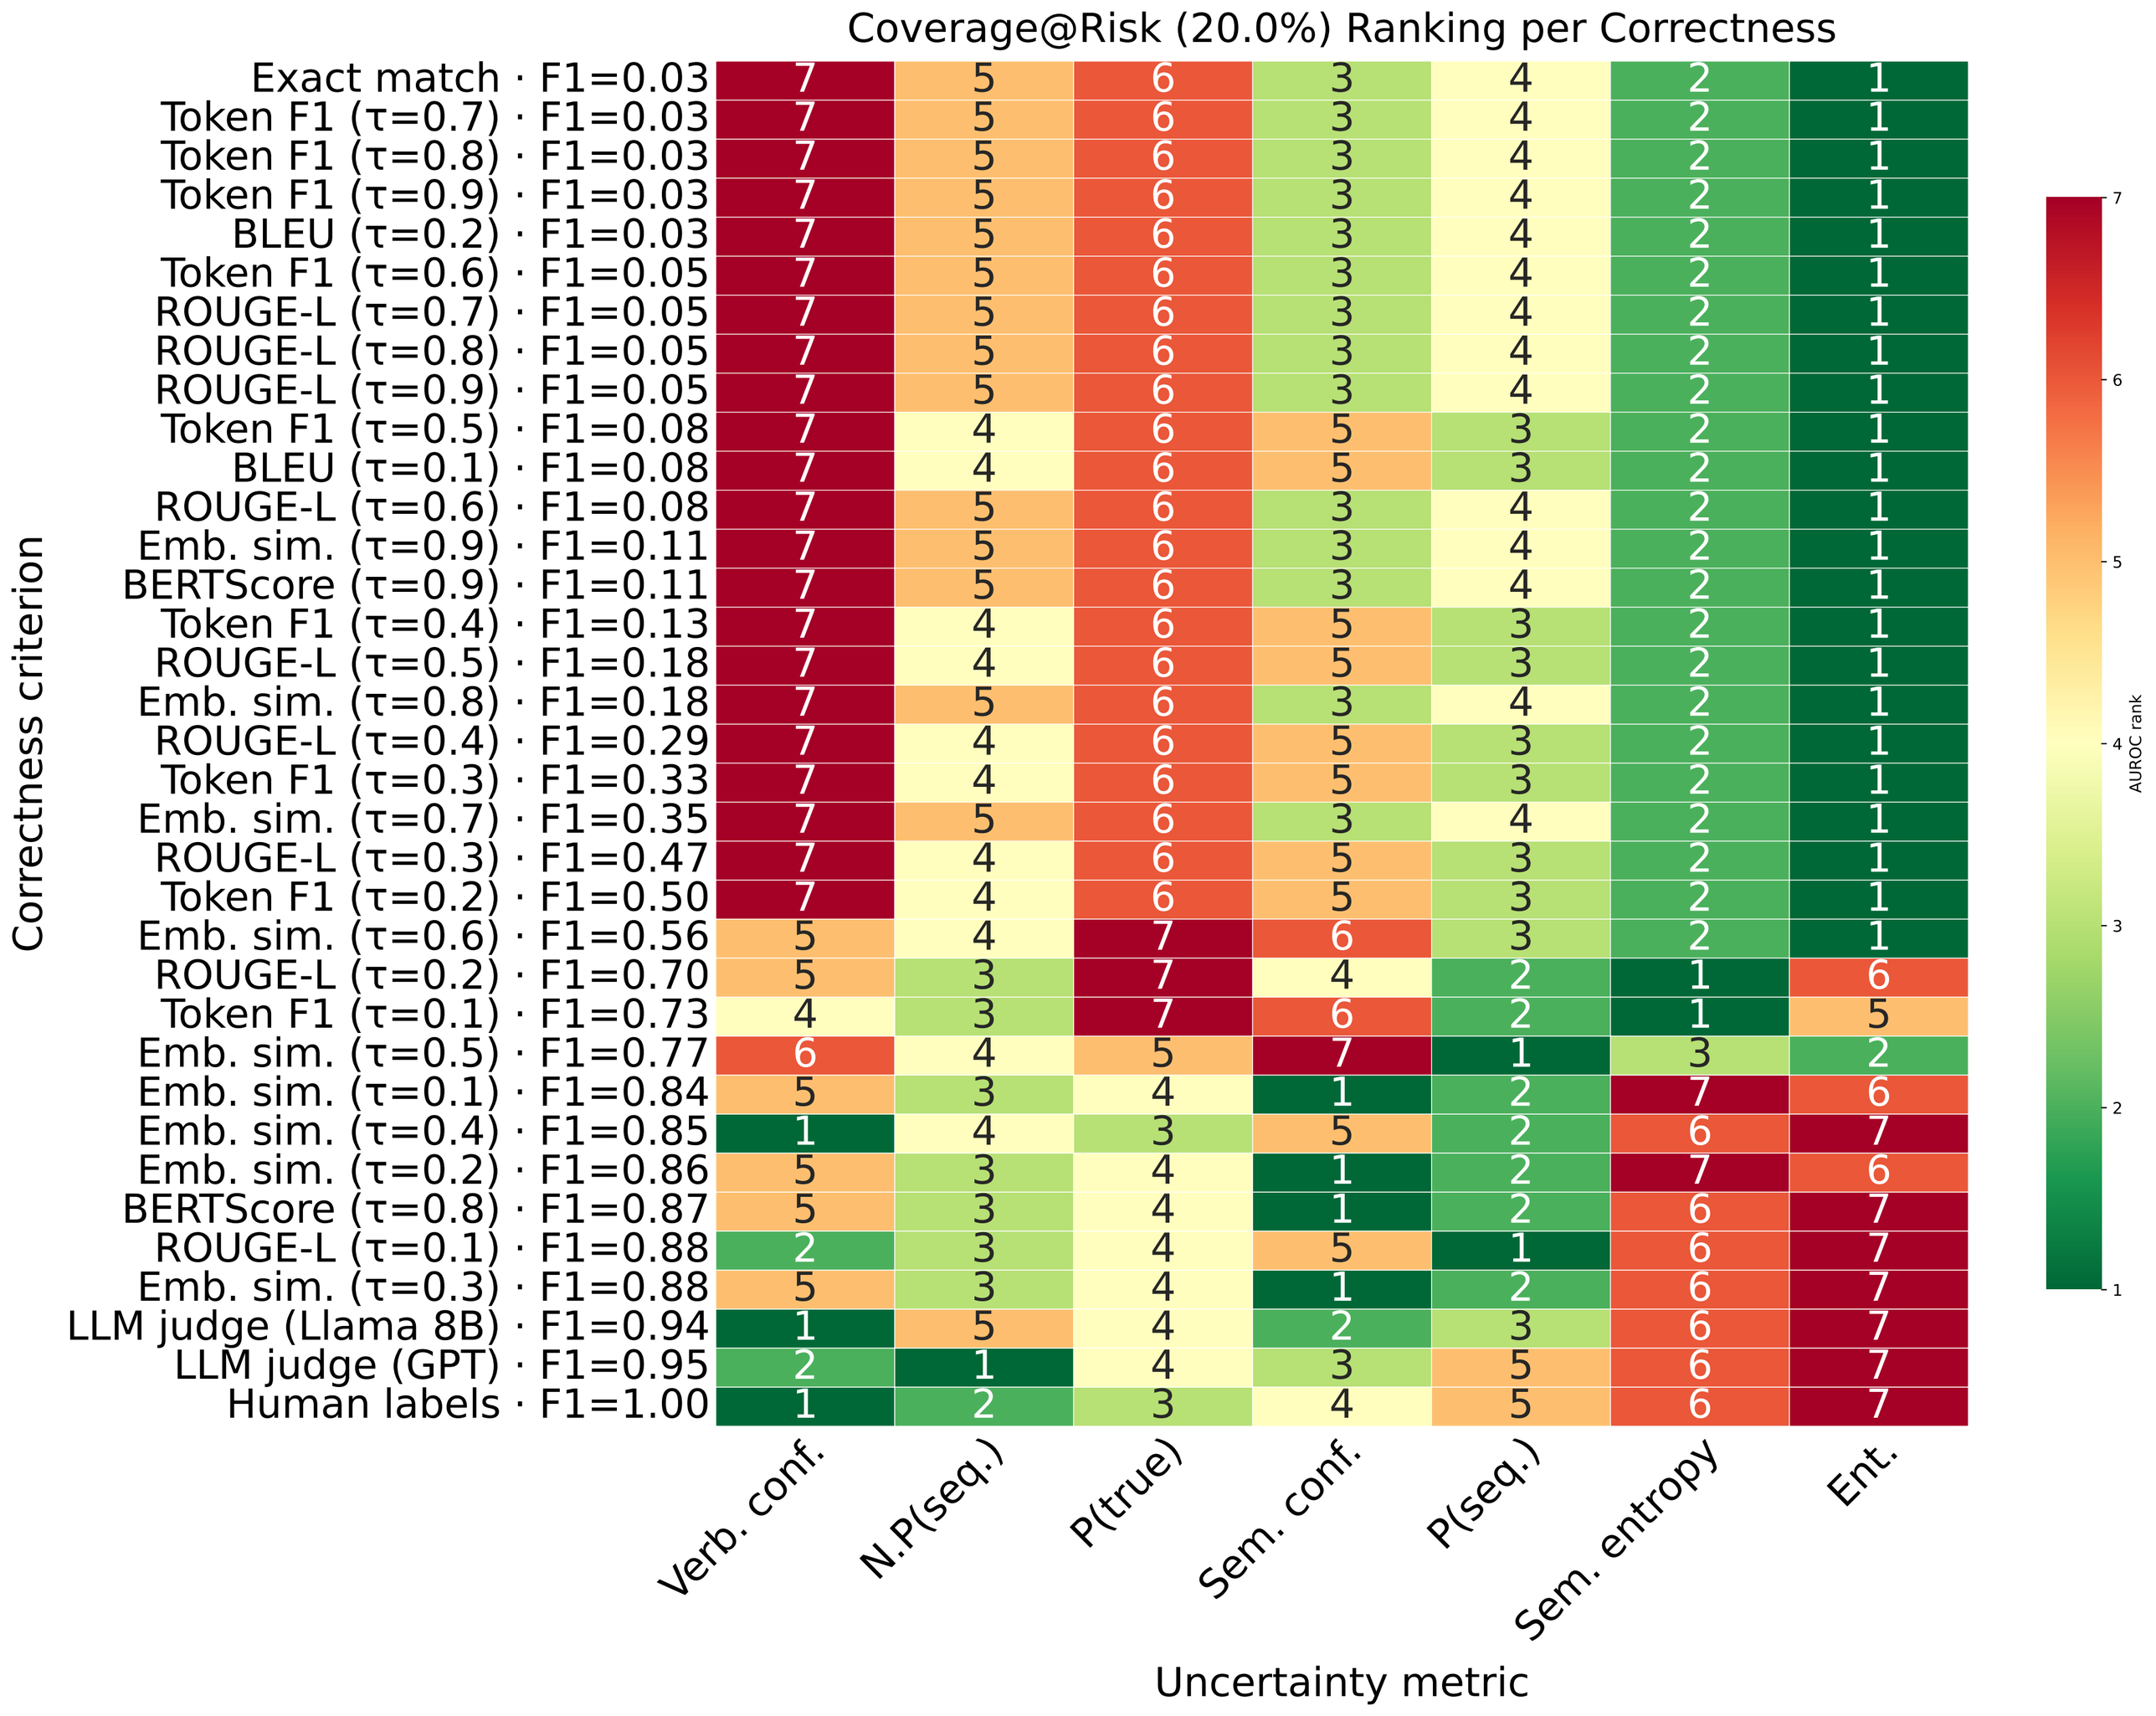
Coverage@Risk (20.0%) Ranking per Correctness
Correctness criterion
Uncertainty metric
Verb. conf.
N.P(seq.)
P(true)
Sem. conf.
P(seq.)
Sem. entropy
Ent.
Exact match · F1=0.03 7 5 6 3 4 2 1
Token F1 (τ=0.7) · F1=0.03 7 5 6 3 4 2 1
Token F1 (τ=0.8) · F1=0.03 7 5 6 3 4 2 1
Token F1 (τ=0.9) · F1=0.03 7 5 6 3 4 2 1
BLEU (τ=0.2) · F1=0.03 7 5 6 3 4 2 1
Token F1 (τ=0.6) · F1=0.05 7 5 6 3 4 2 1
ROUGE-L (τ=0.7) · F1=0.05 7 5 6 3 4 2 1
ROUGE-L (τ=0.8) · F1=0.05 7 5 6 3 4 2 1
ROUGE-L (τ=0.9) · F1=0.05 7 5 6 3 4 2 1
Token F1 (τ=0.5) · F1=0.08 7 4 6 5 3 2 1
BLEU (τ=0.1) · F1=0.08 7 4 6 5 3 2 1
ROUGE-L (τ=0.6) · F1=0.08 7 5 6 3 4 2 1
Emb. sim. (τ=0.9) · F1=0.11 7 5 6 3 4 2 1
BERTScore (τ=0.9) · F1=0.11 7 5 6 3 4 2 1
Token F1 (τ=0.4) · F1=0.13 7 4 6 5 3 2 1
ROUGE-L (τ=0.5) · F1=0.18 7 4 6 5 3 2 1
Emb. sim. (τ=0.8) · F1=0.18 7 5 6 3 4 2 1
ROUGE-L (τ=0.4) · F1=0.29 7 4 6 5 3 2 1
Token F1 (τ=0.3) · F1=0.33 7 4 6 5 3 2 1
Emb. sim. (τ=0.7) · F1=0.35 7 5 6 3 4 2 1
ROUGE-L (τ=0.3) · F1=0.47 7 4 6 5 3 2 1
Token F1 (τ=0.2) · F1=0.50 7 4 6 5 3 2 1
Emb. sim. (τ=0.6) · F1=0.56 5 4 7 6 3 2 1
ROUGE-L (τ=0.2) · F1=0.70 5 3 7 4 2 1 6
Token F1 (τ=0.1) · F1=0.73 4 3 7 6 2 1 5
Emb. sim. (τ=0.5) · F1=0.77 6 4 5 7 1 3 2
Emb. sim. (τ=0.1) · F1=0.84 5 3 4 1 2 7 6
Emb. sim. (τ=0.4) · F1=0.85 1 4 3 5 2 6 7
Emb. sim. (τ=0.2) · F1=0.86 5 3 4 1 2 7 6
BERTScore (τ=0.8) · F1=0.87 5 3 4 1 2 6 7
ROUGE-L (τ=0.1) · F1=0.88 2 3 4 5 1 6 7
Emb. sim. (τ=0.3) · F1=0.88 5 3 4 1 2 6 7
LLM judge (Llama 8B) · F1=0.94 1 5 4 2 3 6 7
LLM judge (GPT) · F1=0.95 2 1 4 3 5 6 7
Human labels · F1=1.00 1 2 3 4 5 6 7
AUROC rank
7
6
5
4
3
2
1