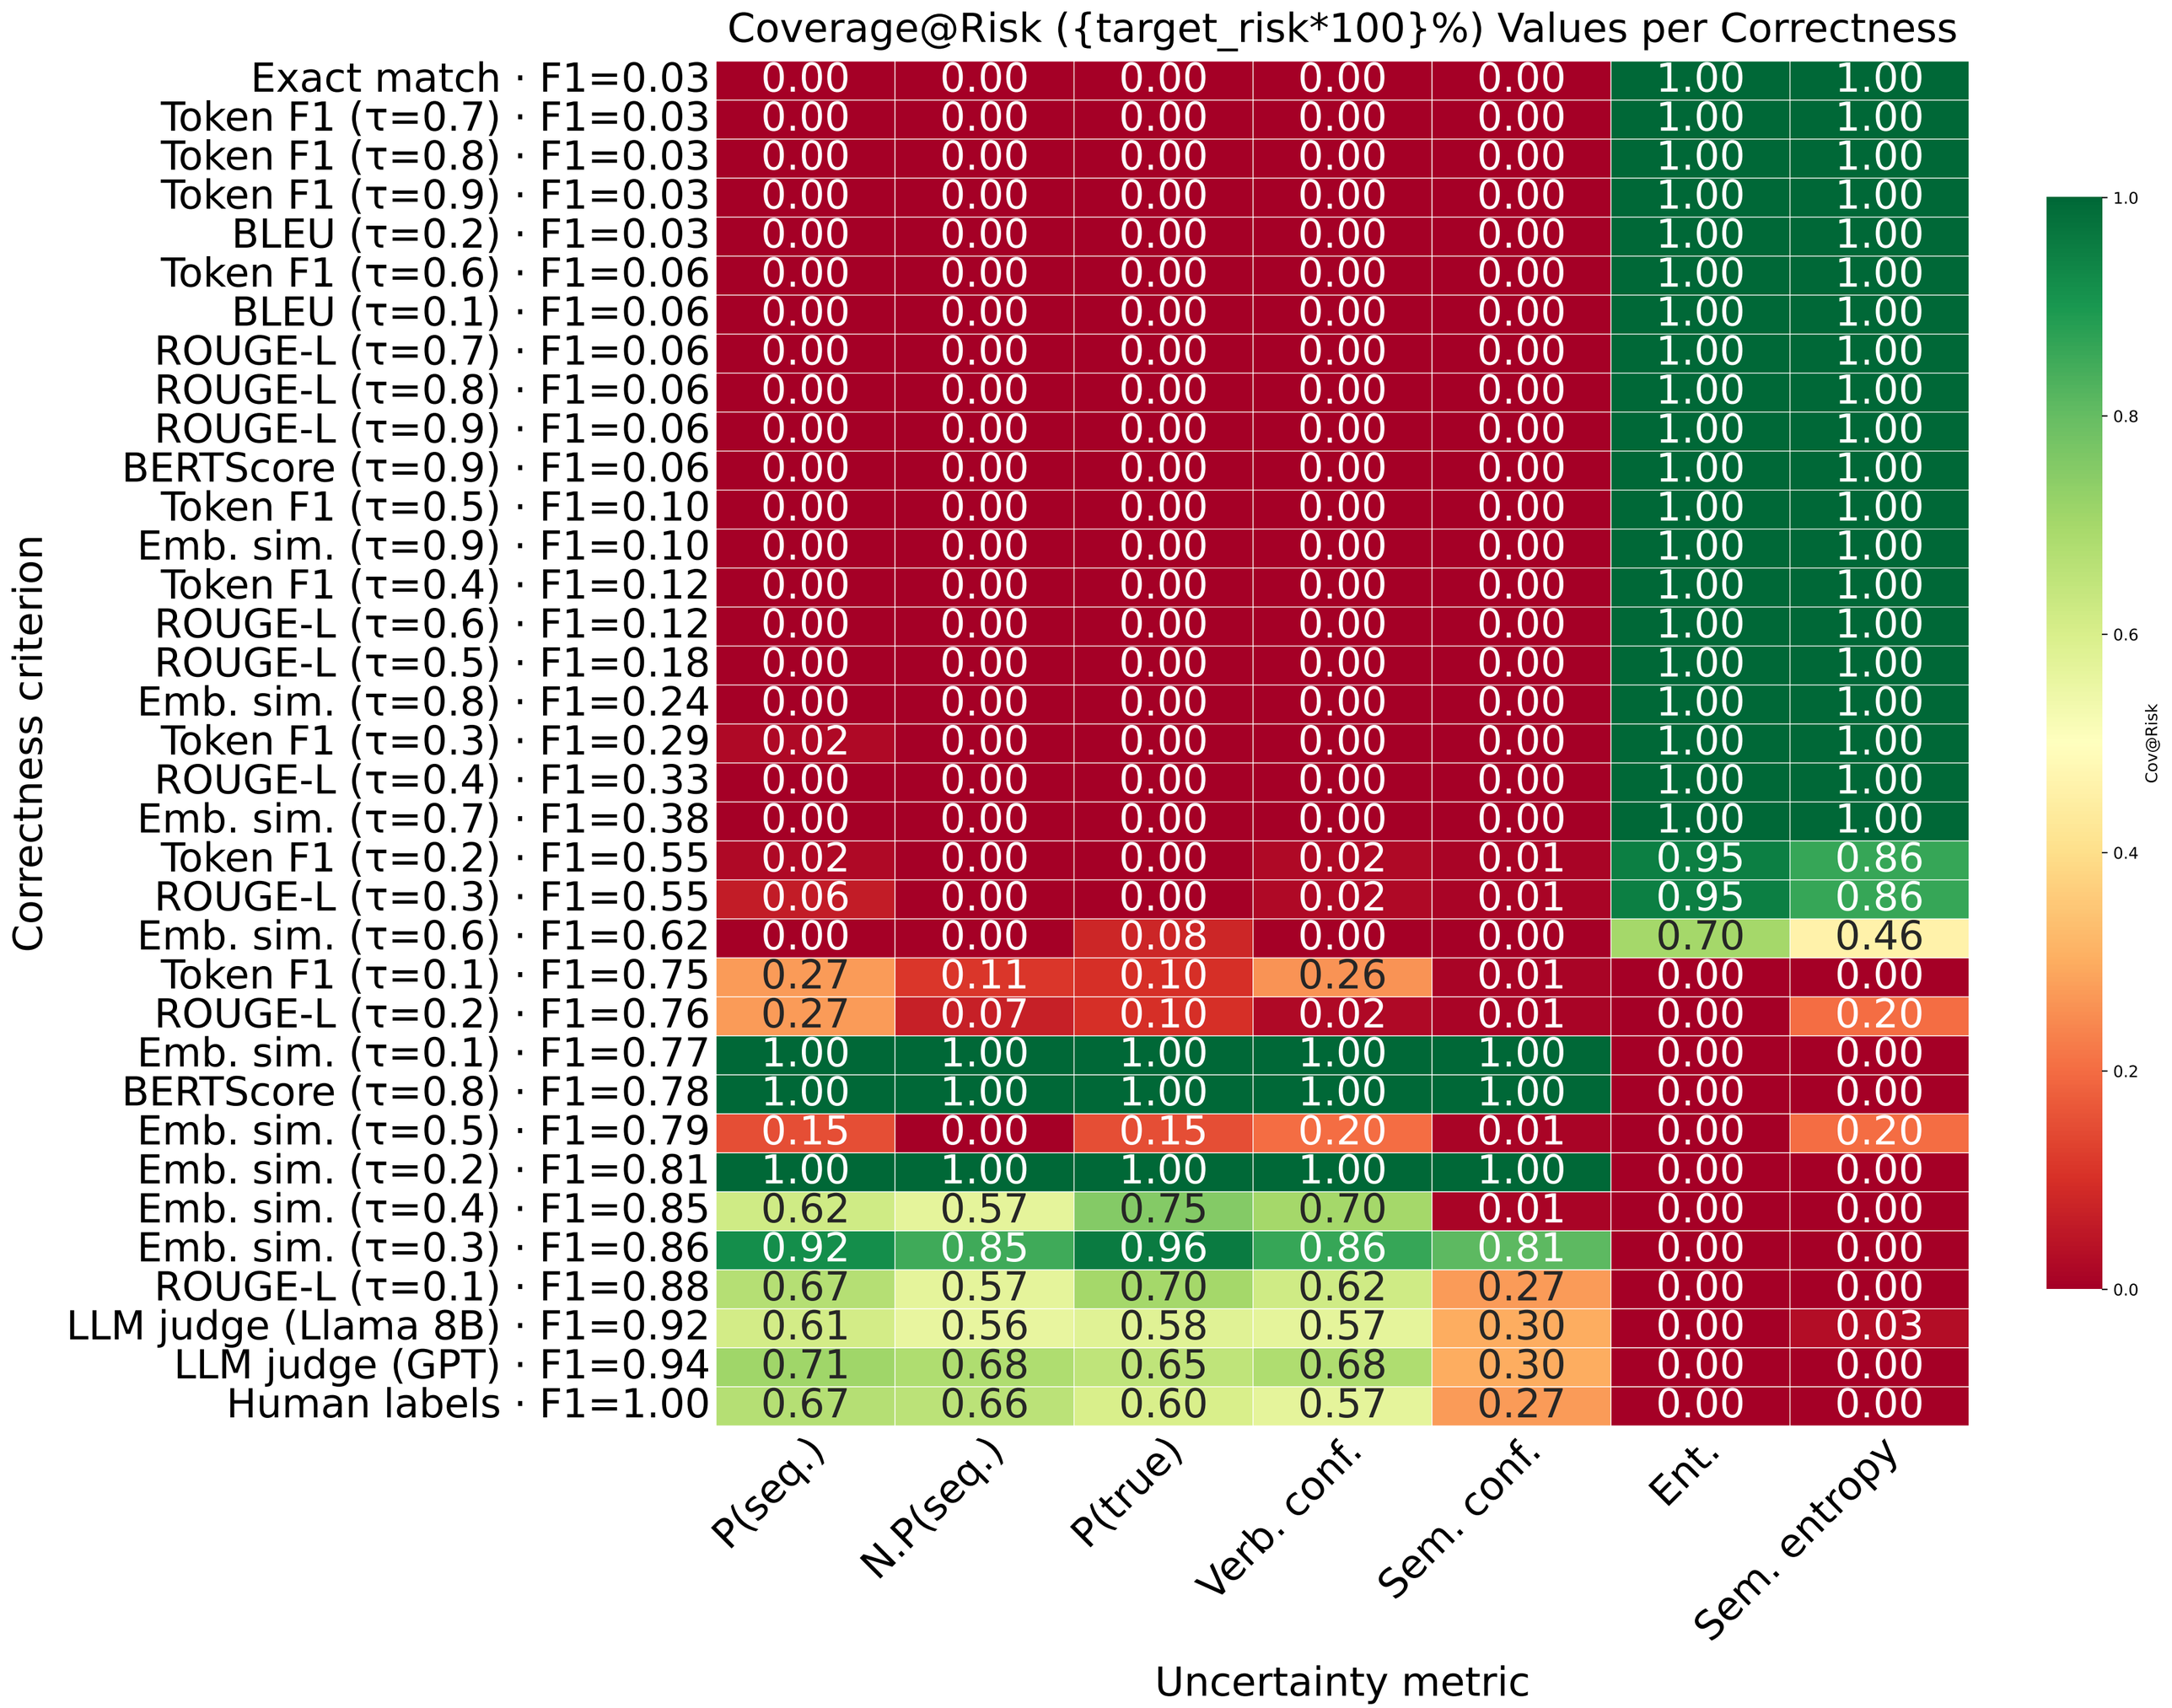
Coverage@Risk ({target_risk*100}%) Values per Correctness
Correctness criterion
Exact match · F1=0.03 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.7) · F1=0.03 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.8) · F1=0.03 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.9) · F1=0.03 0.00 0.00 0.00 0.00 0.00 1.00 1.00
BLEU (τ=0.2) · F1=0.03 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.6) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
BLEU (τ=0.1) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.7) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.8) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.9) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
BERTScore (τ=0.9) · F1=0.06 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.5) · F1=0.10 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Emb. sim. (τ=0.9) · F1=0.10 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.4) · F1=0.12 0.00 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.6) · F1=0.12 0.00 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.5) · F1=0.18 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Emb. sim. (τ=0.8) · F1=0.24 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.3) · F1=0.29 0.02 0.00 0.00 0.00 0.00 1.00 1.00
ROUGE-L (τ=0.4) · F1=0.33 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Emb. sim. (τ=0.7) · F1=0.38 0.00 0.00 0.00 0.00 0.00 1.00 1.00
Token F1 (τ=0.2) · F1=0.55 0.02 0.00 0.00 0.02 0.01 0.95 0.86
ROUGE-L (τ=0.3) · F1=0.55 0.06 0.00 0.00 0.02 0.01 0.95 0.86
Emb. sim. (τ=0.6) · F1=0.62 0.00 0.00 0.08 0.00 0.00 0.70 0.46
Token F1 (τ=0.1) · F1=0.75 0.27 0.11 0.10 0.26 0.01 0.00 0.00
ROUGE-L (τ=0.2) · F1=0.76 0.27 0.07 0.10 0.02 0.01 0.00 0.20
Emb. sim. (τ=0.1) · F1=0.77 1.00 1.00 1.00 1.00 1.00 0.00 0.00
BERTScore (τ=0.8) · F1=0.78 1.00 1.00 1.00 1.00 1.00 0.00 0.00
Emb. sim. (τ=0.5) · F1=0.79 0.15 0.00 0.15 0.20 0.01 0.00 0.20
Emb. sim. (τ=0.2) · F1=0.81 1.00 1.00 1.00 1.00 1.00 0.00 0.00
Emb. sim. (τ=0.4) · F1=0.85 0.62 0.57 0.75 0.70 0.01 0.00 0.00
Emb. sim. (τ=0.3) · F1=0.86 0.92 0.85 0.96 0.86 0.81 0.00 0.00
ROUGE-L (τ=0.1) · F1=0.88 0.67 0.57 0.70 0.62 0.27 0.00 0.00
LLM judge (Llama 8B) · F1=0.92 0.61 0.56 0.58 0.57 0.30 0.00 0.03
LLM judge (GPT) · F1=0.94 0.71 0.68 0.65 0.68 0.30 0.00 0.00
Human labels · F1=1.00 0.67 0.66 0.60 0.57 0.27 0.00 0.00
P(seq.)
N.P(seq.)
P(true)
Verb. conf.
Sem. conf.
Ent.
Sem. entropy
Uncertainty metric
Cov@Risk
1.0
0.8
0.6
0.4
0.2
0.0