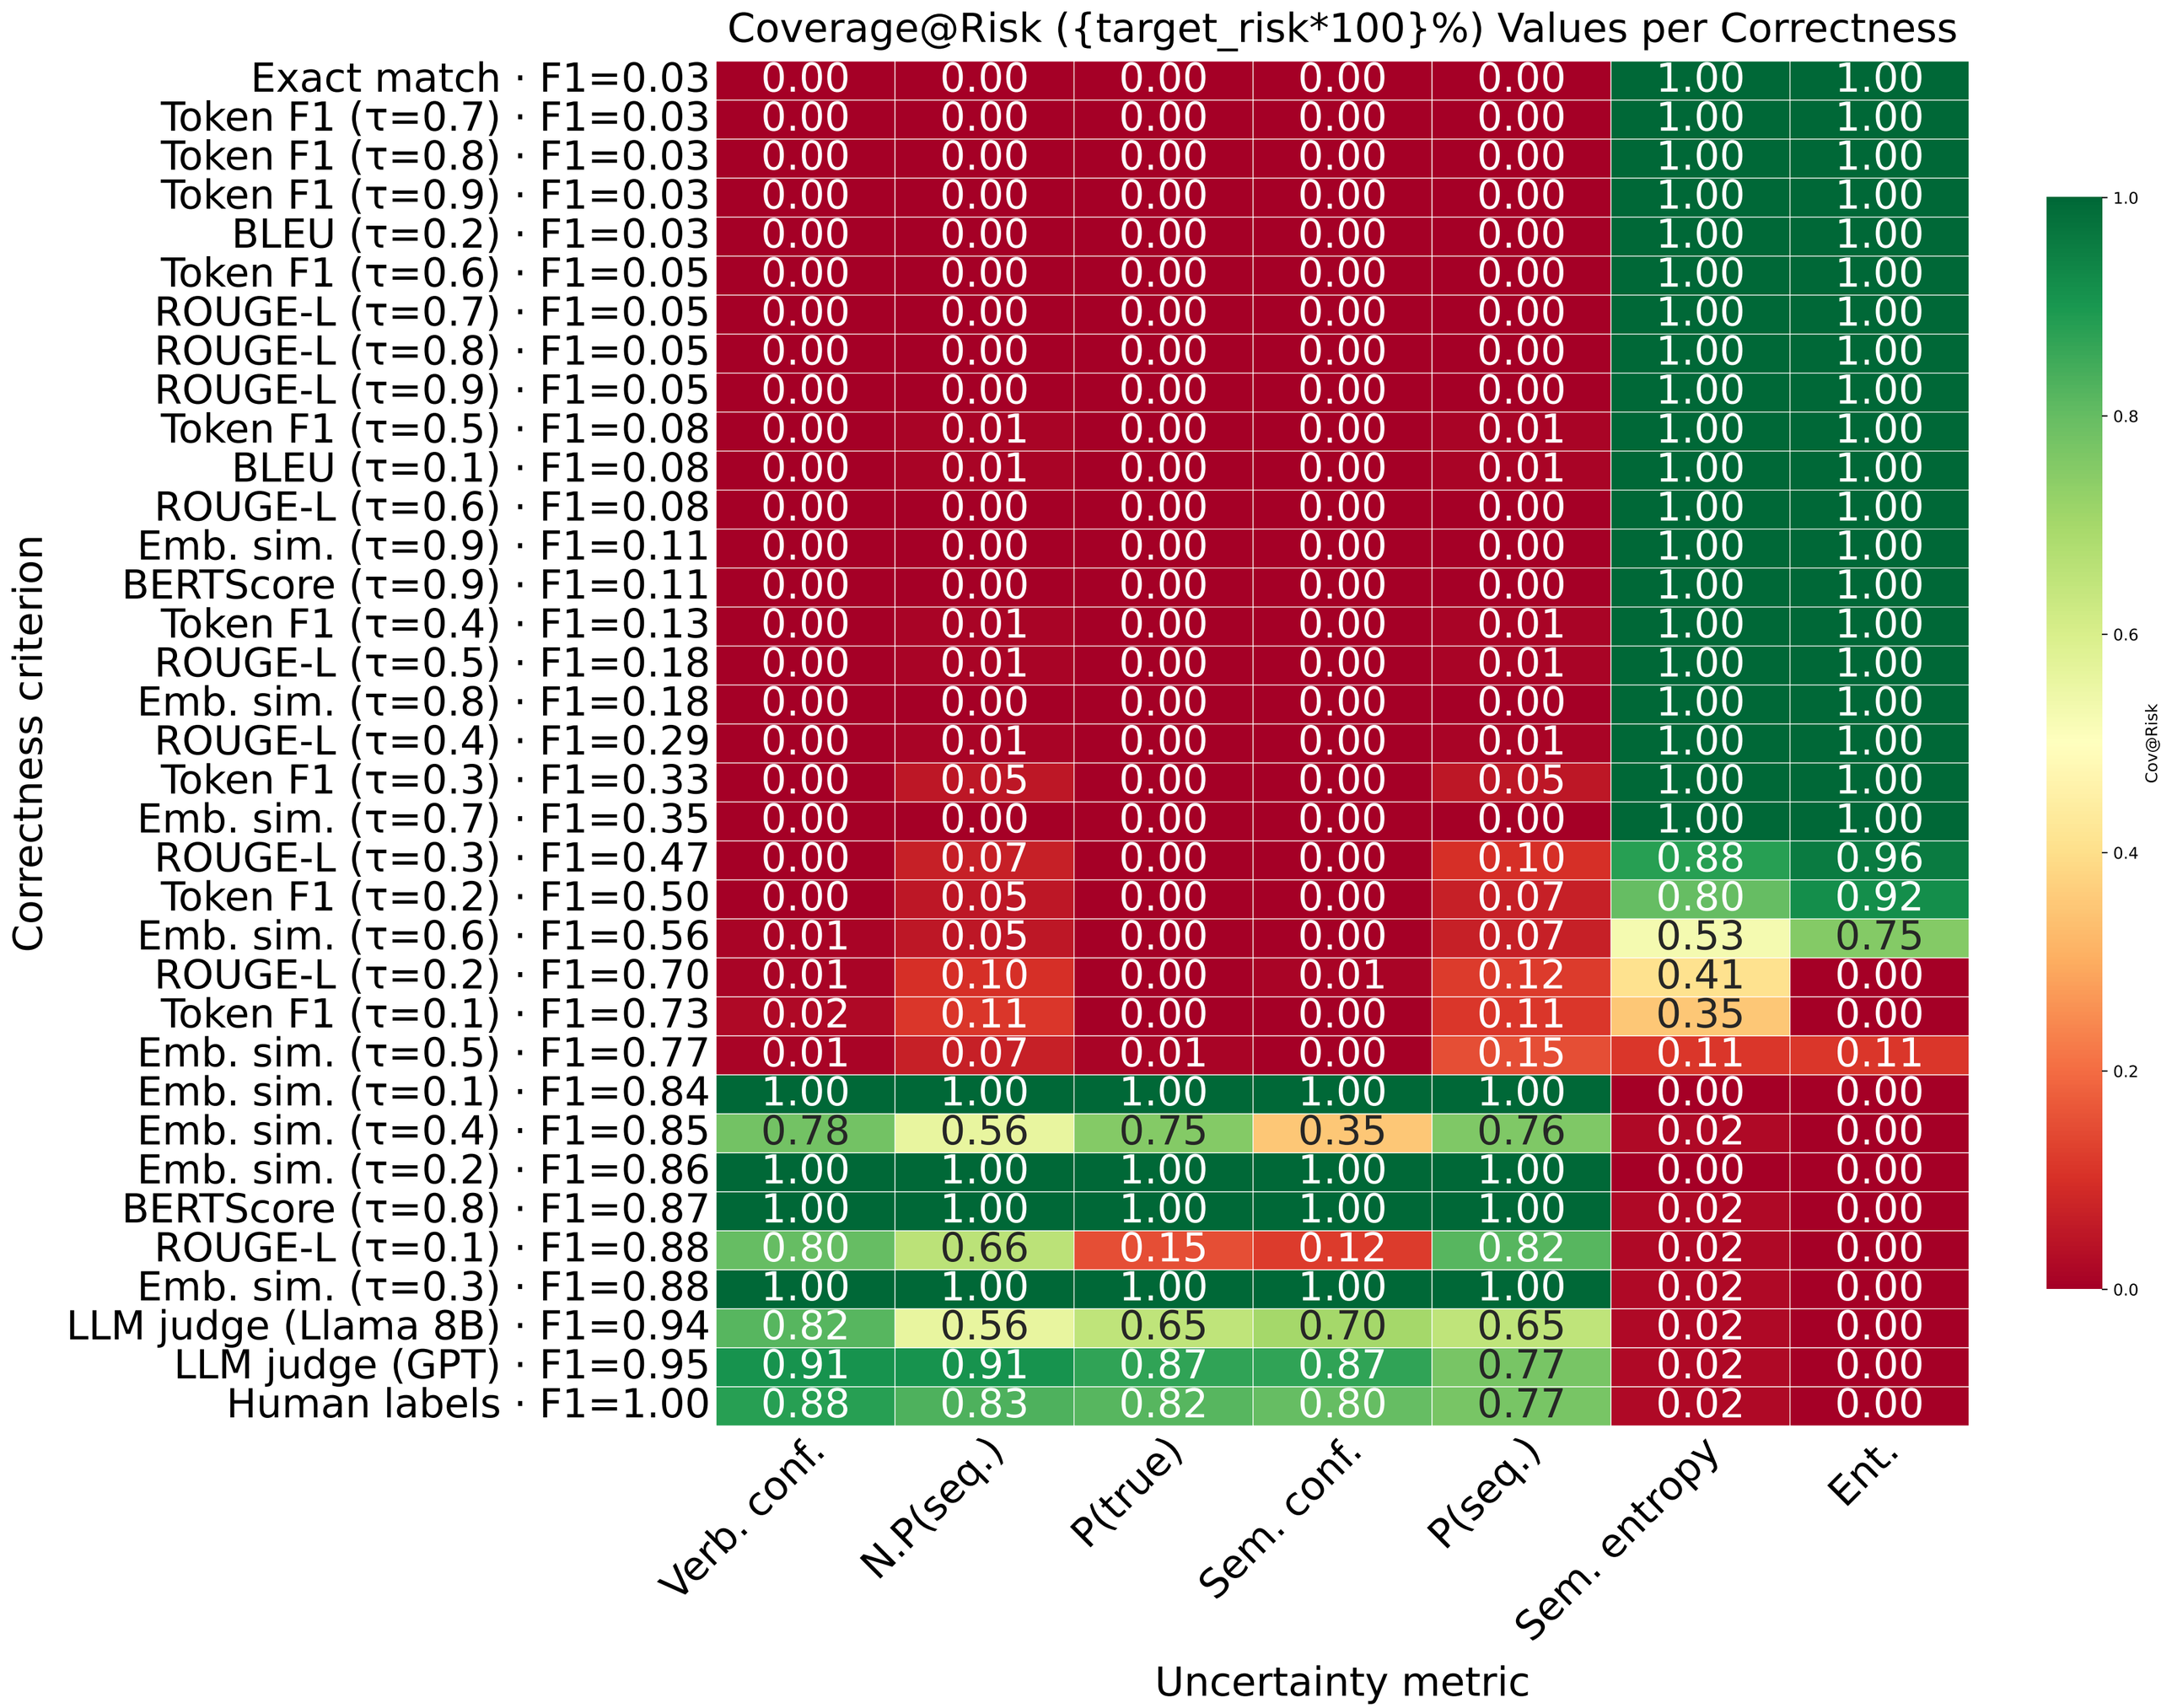
Coverage@Risk ({target_risk*100}%) Values per Correctness
Correctness criterion
Uncertainty metric
Cov@Risk
Exact match · F1=0.03 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.7) · F1=0.03 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.8) · F1=0.03 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.9) · F1=0.03 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
BLEU (τ=0.2) · F1=0.03 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.6) · F1=0.05 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
ROUGE-L (τ=0.7) · F1=0.05 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
ROUGE-L (τ=0.8) · F1=0.05 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
ROUGE-L (τ=0.9) · F1=0.05 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.5) · F1=0.08 | 0.00 | 0.01 | 0.00 | 0.00 | 0.01 | 1.00 | 1.00
BLEU (τ=0.1) · F1=0.08 | 0.00 | 0.01 | 0.00 | 0.00 | 0.01 | 1.00 | 1.00
ROUGE-L (τ=0.6) · F1=0.08 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Emb. sim. (τ=0.9) · F1=0.11 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
BERTScore (τ=0.9) · F1=0.11 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
Token F1 (τ=0.4) · F1=0.13 | 0.00 | 0.01 | 0.00 | 0.00 | 0.01 | 1.00 | 1.00
ROUGE-L (τ=0.5) · F1=0.18 | 0.00 | 0.01 | 0.00 | 0.00 | 0.01 | 1.00 | 1.00
Emb. sim. (τ=0.8) · F1=0.18 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
ROUGE-L (τ=0.4) · F1=0.29 | 0.00 | 0.01 | 0.00 | 0.00 | 0.01 | 1.00 | 1.00
Token F1 (τ=0.3) · F1=0.33 | 0.00 | 0.05 | 0.00 | 0.00 | 0.05 | 1.00 | 1.00
Emb. sim. (τ=0.7) · F1=0.35 | 0.00 | 0.00 | 0.00 | 0.00 | 0.00 | 1.00 | 1.00
ROUGE-L (τ=0.3) · F1=0.47 | 0.00 | 0.07 | 0.00 | 0.00 | 0.10 | 0.88 | 0.96
Token F1 (τ=0.2) · F1=0.50 | 0.00 | 0.05 | 0.00 | 0.00 | 0.07 | 0.80 | 0.92
Emb. sim. (τ=0.6) · F1=0.56 | 0.01 | 0.05 | 0.00 | 0.00 | 0.07 | 0.53 | 0.75
ROUGE-L (τ=0.2) · F1=0.70 | 0.01 | 0.10 | 0.00 | 0.01 | 0.12 | 0.41 | 0.00
Token F1 (τ=0.1) · F1=0.73 | 0.02 | 0.11 | 0.00 | 0.00 | 0.11 | 0.35 | 0.00
Emb. sim. (τ=0.5) · F1=0.77 | 0.01 | 0.07 | 0.01 | 0.00 | 0.15 | 0.11 | 0.11
Emb. sim. (τ=0.1) · F1=0.84 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.00 | 0.00
Emb. sim. (τ=0.4) · F1=0.85 | 0.78 | 0.56 | 0.75 | 0.35 | 0.76 | 0.02 | 0.00
Emb. sim. (τ=0.2) · F1=0.86 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.00 | 0.00
BERTScore (τ=0.8) · F1=0.87 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.02 | 0.00
ROUGE-L (τ=0.1) · F1=0.88 | 0.80 | 0.66 | 0.15 | 0.12 | 0.82 | 0.02 | 0.00
Emb. sim. (τ=0.3) · F1=0.88 | 1.00 | 1.00 | 1.00 | 1.00 | 1.00 | 0.02 | 0.00
LLM judge (Llama 8B) · F1=0.94 | 0.82 | 0.56 | 0.65 | 0.70 | 0.65 | 0.02 | 0.00
LLM judge (GPT) · F1=0.95 | 0.91 | 0.91 | 0.87 | 0.87 | 0.77 | 0.02 | 0.00
Human labels · F1=1.00 | 0.88 | 0.83 | 0.82 | 0.80 | 0.77 | 0.02 | 0.00
Verb. conf.
N.P(seq.)
P(true)
Sem. conf.
P(seq.)
Sem. entropy
Ent.
1.0
0.8
0.6
0.4
0.2
0.0