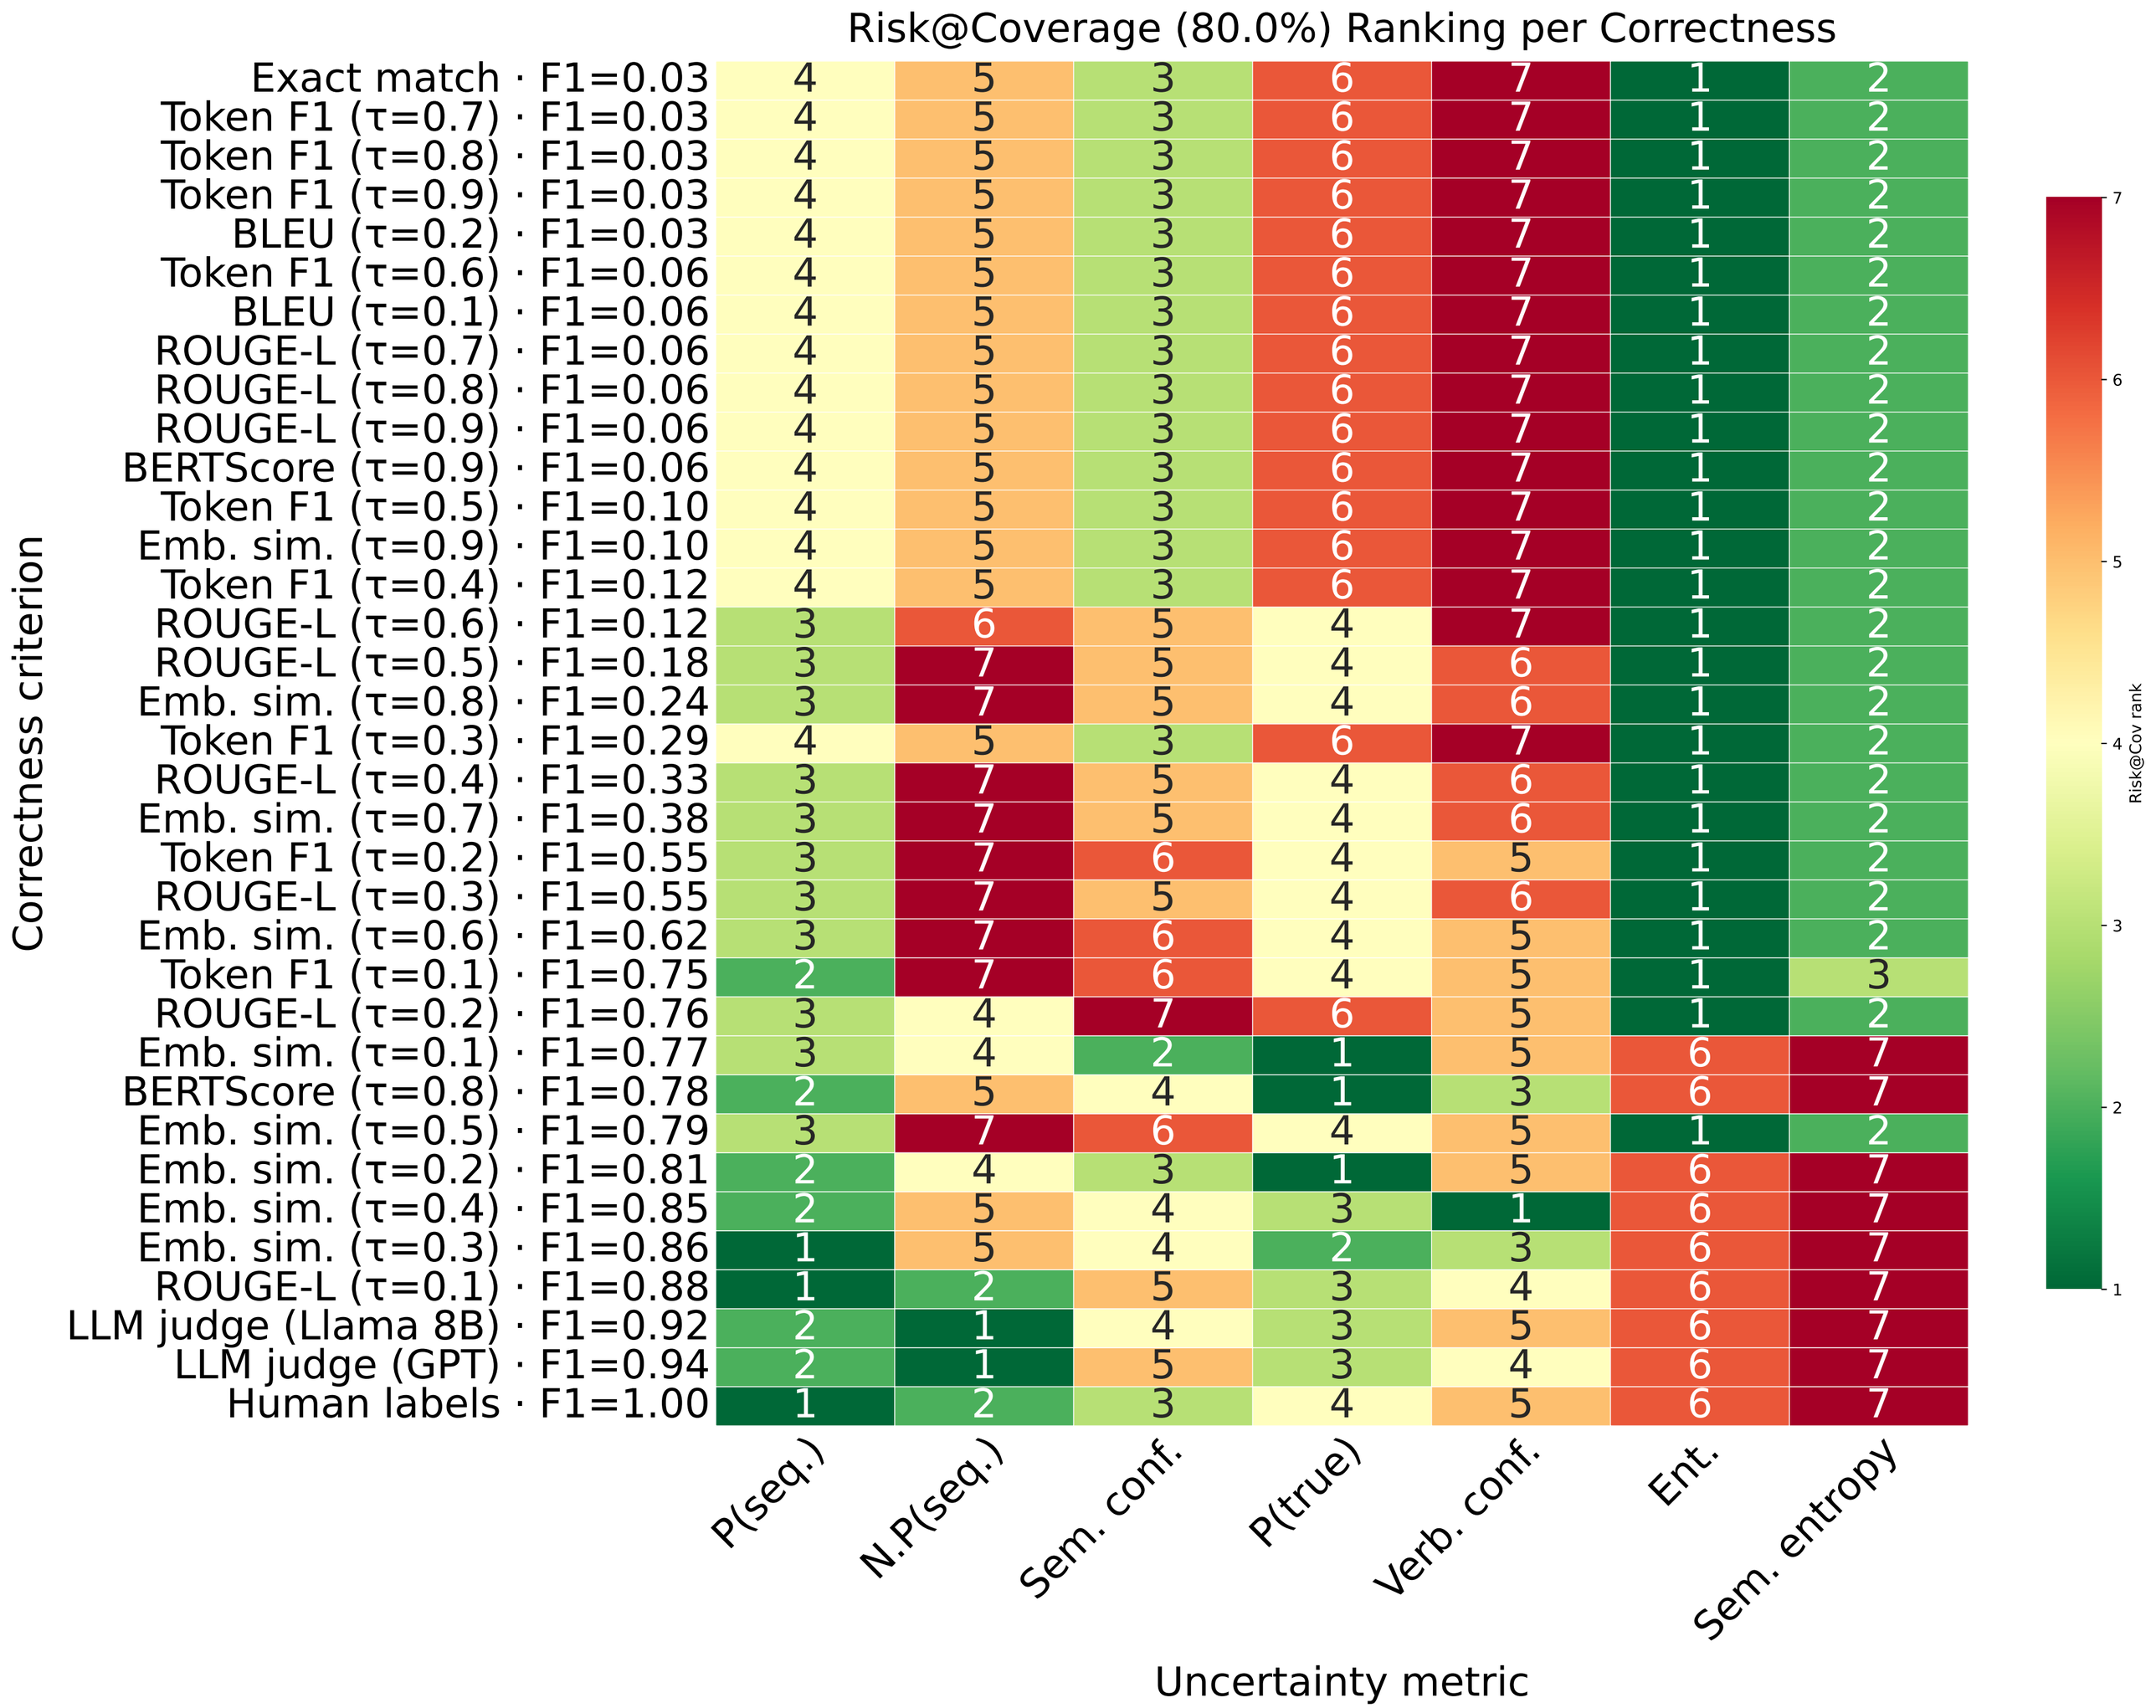
Risk@Coverage (80.0%) Ranking per Correctness
Correctness criterion
Uncertainty metric
Risk@Cov rank
Exact match · F1=0.03 4 5 3 6 7 1 2
Token F1 (τ=0.7) · F1=0.03 4 5 3 6 7 1 2
Token F1 (τ=0.8) · F1=0.03 4 5 3 6 7 1 2
Token F1 (τ=0.9) · F1=0.03 4 5 3 6 7 1 2
BLEU (τ=0.2) · F1=0.03 4 5 3 6 7 1 2
Token F1 (τ=0.6) · F1=0.06 4 5 3 6 7 1 2
BLEU (τ=0.1) · F1=0.06 4 5 3 6 7 1 2
ROUGE-L (τ=0.7) · F1=0.06 4 5 3 6 7 1 2
ROUGE-L (τ=0.8) · F1=0.06 4 5 3 6 7 1 2
ROUGE-L (τ=0.9) · F1=0.06 4 5 3 6 7 1 2
BERTScore (τ=0.9) · F1=0.06 4 5 3 6 7 1 2
Token F1 (τ=0.5) · F1=0.10 4 5 3 6 7 1 2
Emb. sim. (τ=0.9) · F1=0.10 4 5 3 6 7 1 2
Token F1 (τ=0.4) · F1=0.12 4 5 3 6 7 1 2
ROUGE-L (τ=0.6) · F1=0.12 3 6 5 4 7 1 2
ROUGE-L (τ=0.5) · F1=0.18 3 7 5 4 6 1 2
Emb. sim. (τ=0.8) · F1=0.24 3 7 5 4 6 1 2
Token F1 (τ=0.3) · F1=0.29 4 5 3 6 7 1 2
ROUGE-L (τ=0.4) · F1=0.33 3 7 5 4 6 1 2
Emb. sim. (τ=0.7) · F1=0.38 3 7 5 4 6 1 2
Token F1 (τ=0.2) · F1=0.55 3 7 6 4 5 1 2
ROUGE-L (τ=0.3) · F1=0.55 3 7 5 4 6 1 2
Emb. sim. (τ=0.6) · F1=0.62 3 7 6 4 5 1 2
Token F1 (τ=0.1) · F1=0.75 2 7 6 4 5 1 3
ROUGE-L (τ=0.2) · F1=0.76 3 4 7 6 5 1 2
Emb. sim. (τ=0.1) · F1=0.77 3 4 2 1 5 6 7
BERTScore (τ=0.8) · F1=0.78 2 5 4 1 3 6 7
Emb. sim. (τ=0.5) · F1=0.79 3 7 6 4 5 1 2
Emb. sim. (τ=0.2) · F1=0.81 2 4 3 1 5 6 7
Emb. sim. (τ=0.4) · F1=0.85 2 5 4 3 1 6 7
Emb. sim. (τ=0.3) · F1=0.86 1 5 4 2 3 6 7
ROUGE-L (τ=0.1) · F1=0.88 1 2 5 3 4 6 7
LLM judge (Llama 8B) · F1=0.92 2 1 4 3 5 6 7
LLM judge (GPT) · F1=0.94 2 1 5 3 4 6 7
Human labels · F1=1.00 1 2 3 4 5 6 7
P(seq.)
N.P(seq.)
Sem. conf.
P(true)
Verb. conf.
Ent.
Sem. entropy
7
6
5
4
3
2
1