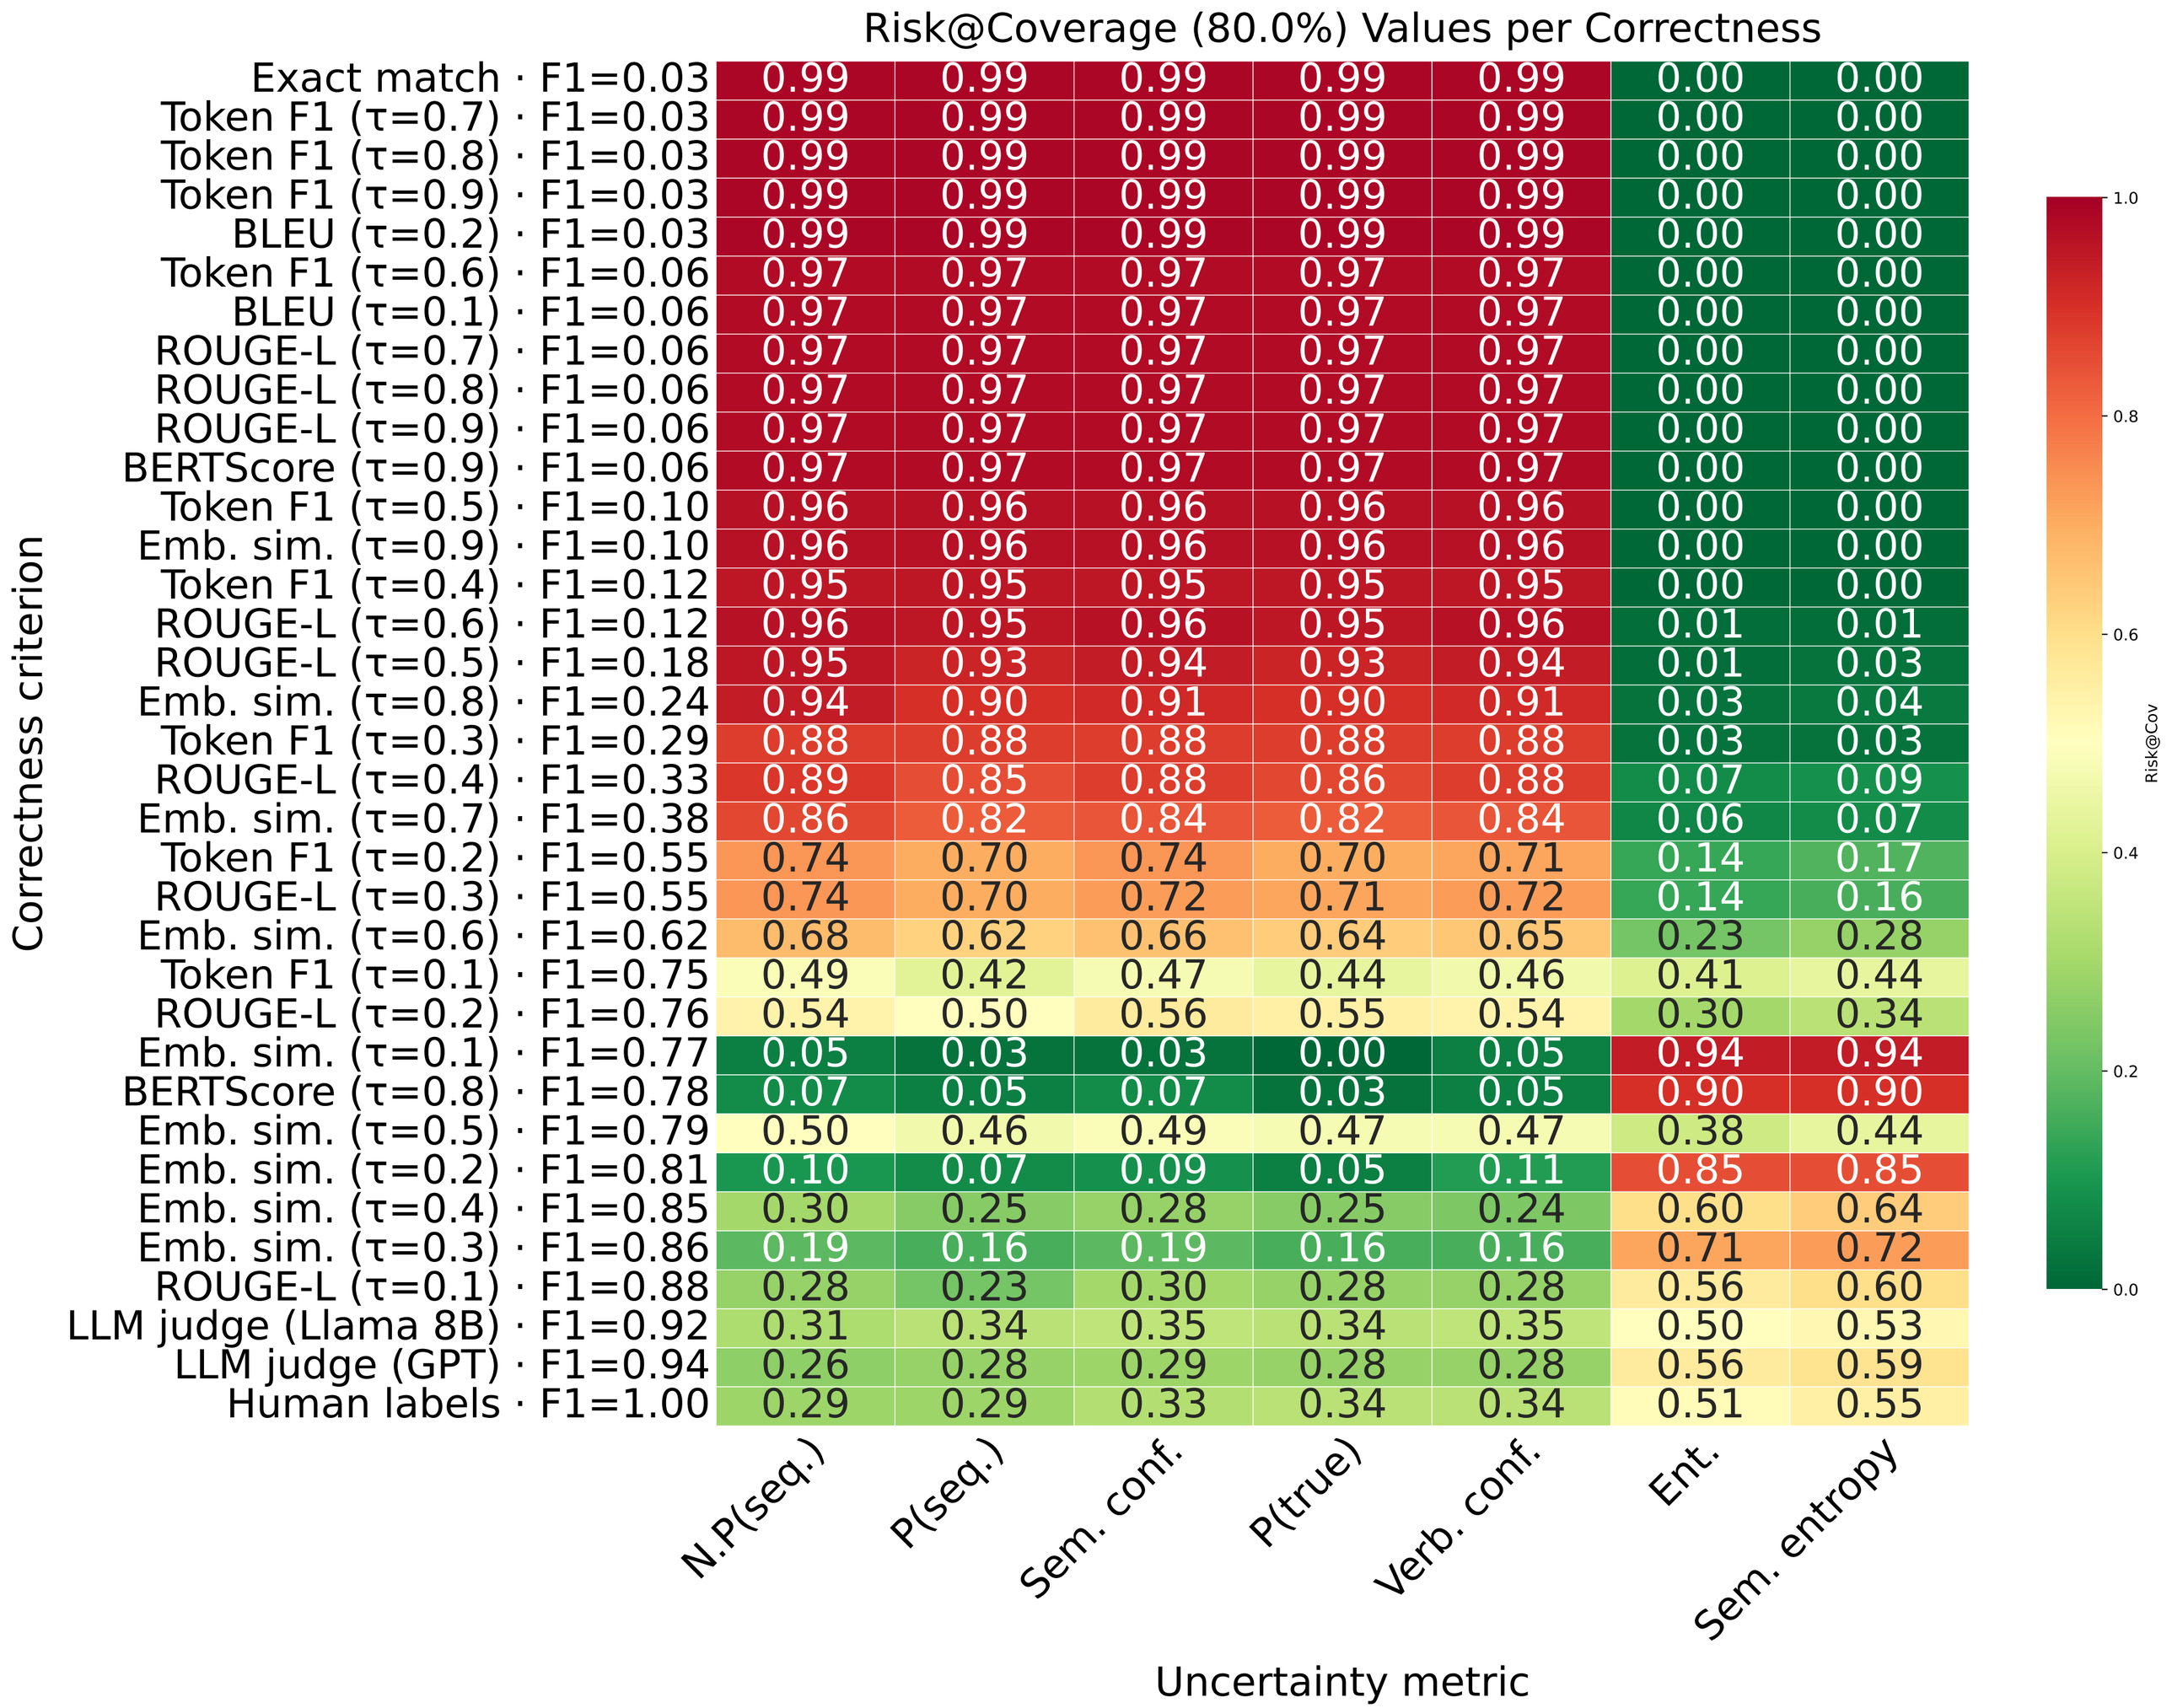
Risk@Coverage (80.0%) Values per Correctness
Correctness criterion
Uncertainty metric
N.P(seq.)
P(seq.)
Sem. conf.
P(true)
Verb. conf.
Ent.
Sem. entropy
Exact match · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.7) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.8) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.9) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
BLEU (τ=0.2) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.6) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
BLEU (τ=0.1) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
ROUGE-L (τ=0.7) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
ROUGE-L (τ=0.8) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
ROUGE-L (τ=0.9) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
BERTScore (τ=0.9) · F1=0.06 0.97 0.97 0.97 0.97 0.97 0.00 0.00
Token F1 (τ=0.5) · F1=0.10 0.96 0.96 0.96 0.96 0.96 0.00 0.00
Emb. sim. (τ=0.9) · F1=0.10 0.96 0.96 0.96 0.96 0.96 0.00 0.00
Token F1 (τ=0.4) · F1=0.12 0.95 0.95 0.95 0.95 0.95 0.00 0.00
ROUGE-L (τ=0.6) · F1=0.12 0.96 0.95 0.96 0.95 0.96 0.01 0.01
ROUGE-L (τ=0.5) · F1=0.18 0.95 0.93 0.94 0.93 0.94 0.01 0.03
Emb. sim. (τ=0.8) · F1=0.24 0.94 0.90 0.91 0.90 0.91 0.03 0.04
Token F1 (τ=0.3) · F1=0.29 0.88 0.88 0.88 0.88 0.88 0.03 0.03
ROUGE-L (τ=0.4) · F1=0.33 0.89 0.85 0.88 0.86 0.88 0.07 0.09
Emb. sim. (τ=0.7) · F1=0.38 0.86 0.82 0.84 0.82 0.84 0.06 0.07
Token F1 (τ=0.2) · F1=0.55 0.74 0.70 0.74 0.70 0.71 0.14 0.17
ROUGE-L (τ=0.3) · F1=0.55 0.74 0.70 0.72 0.71 0.72 0.14 0.16
Emb. sim. (τ=0.6) · F1=0.62 0.68 0.62 0.66 0.64 0.65 0.23 0.28
Token F1 (τ=0.1) · F1=0.75 0.49 0.42 0.47 0.44 0.46 0.41 0.44
ROUGE-L (τ=0.2) · F1=0.76 0.54 0.50 0.56 0.55 0.54 0.30 0.34
Emb. sim. (τ=0.1) · F1=0.77 0.05 0.03 0.03 0.00 0.05 0.94 0.94
BERTScore (τ=0.8) · F1=0.78 0.07 0.05 0.07 0.03 0.05 0.90 0.90
Emb. sim. (τ=0.5) · F1=0.79 0.50 0.46 0.49 0.47 0.47 0.38 0.44
Emb. sim. (τ=0.2) · F1=0.81 0.10 0.07 0.09 0.05 0.11 0.85 0.85
Emb. sim. (τ=0.4) · F1=0.85 0.30 0.25 0.28 0.25 0.24 0.60 0.64
Emb. sim. (τ=0.3) · F1=0.86 0.19 0.16 0.19 0.16 0.16 0.71 0.72
ROUGE-L (τ=0.1) · F1=0.88 0.28 0.23 0.30 0.28 0.28 0.56 0.60
LLM judge (Llama 8B) · F1=0.92 0.31 0.34 0.35 0.34 0.35 0.50 0.53
LLM judge (GPT) · F1=0.94 0.26 0.28 0.29 0.28 0.28 0.56 0.59
Human labels · F1=1.00 0.29 0.29 0.33 0.34 0.34 0.51 0.55
Risk@Cov
1.0
0.8
0.6
0.4
0.2
0.0