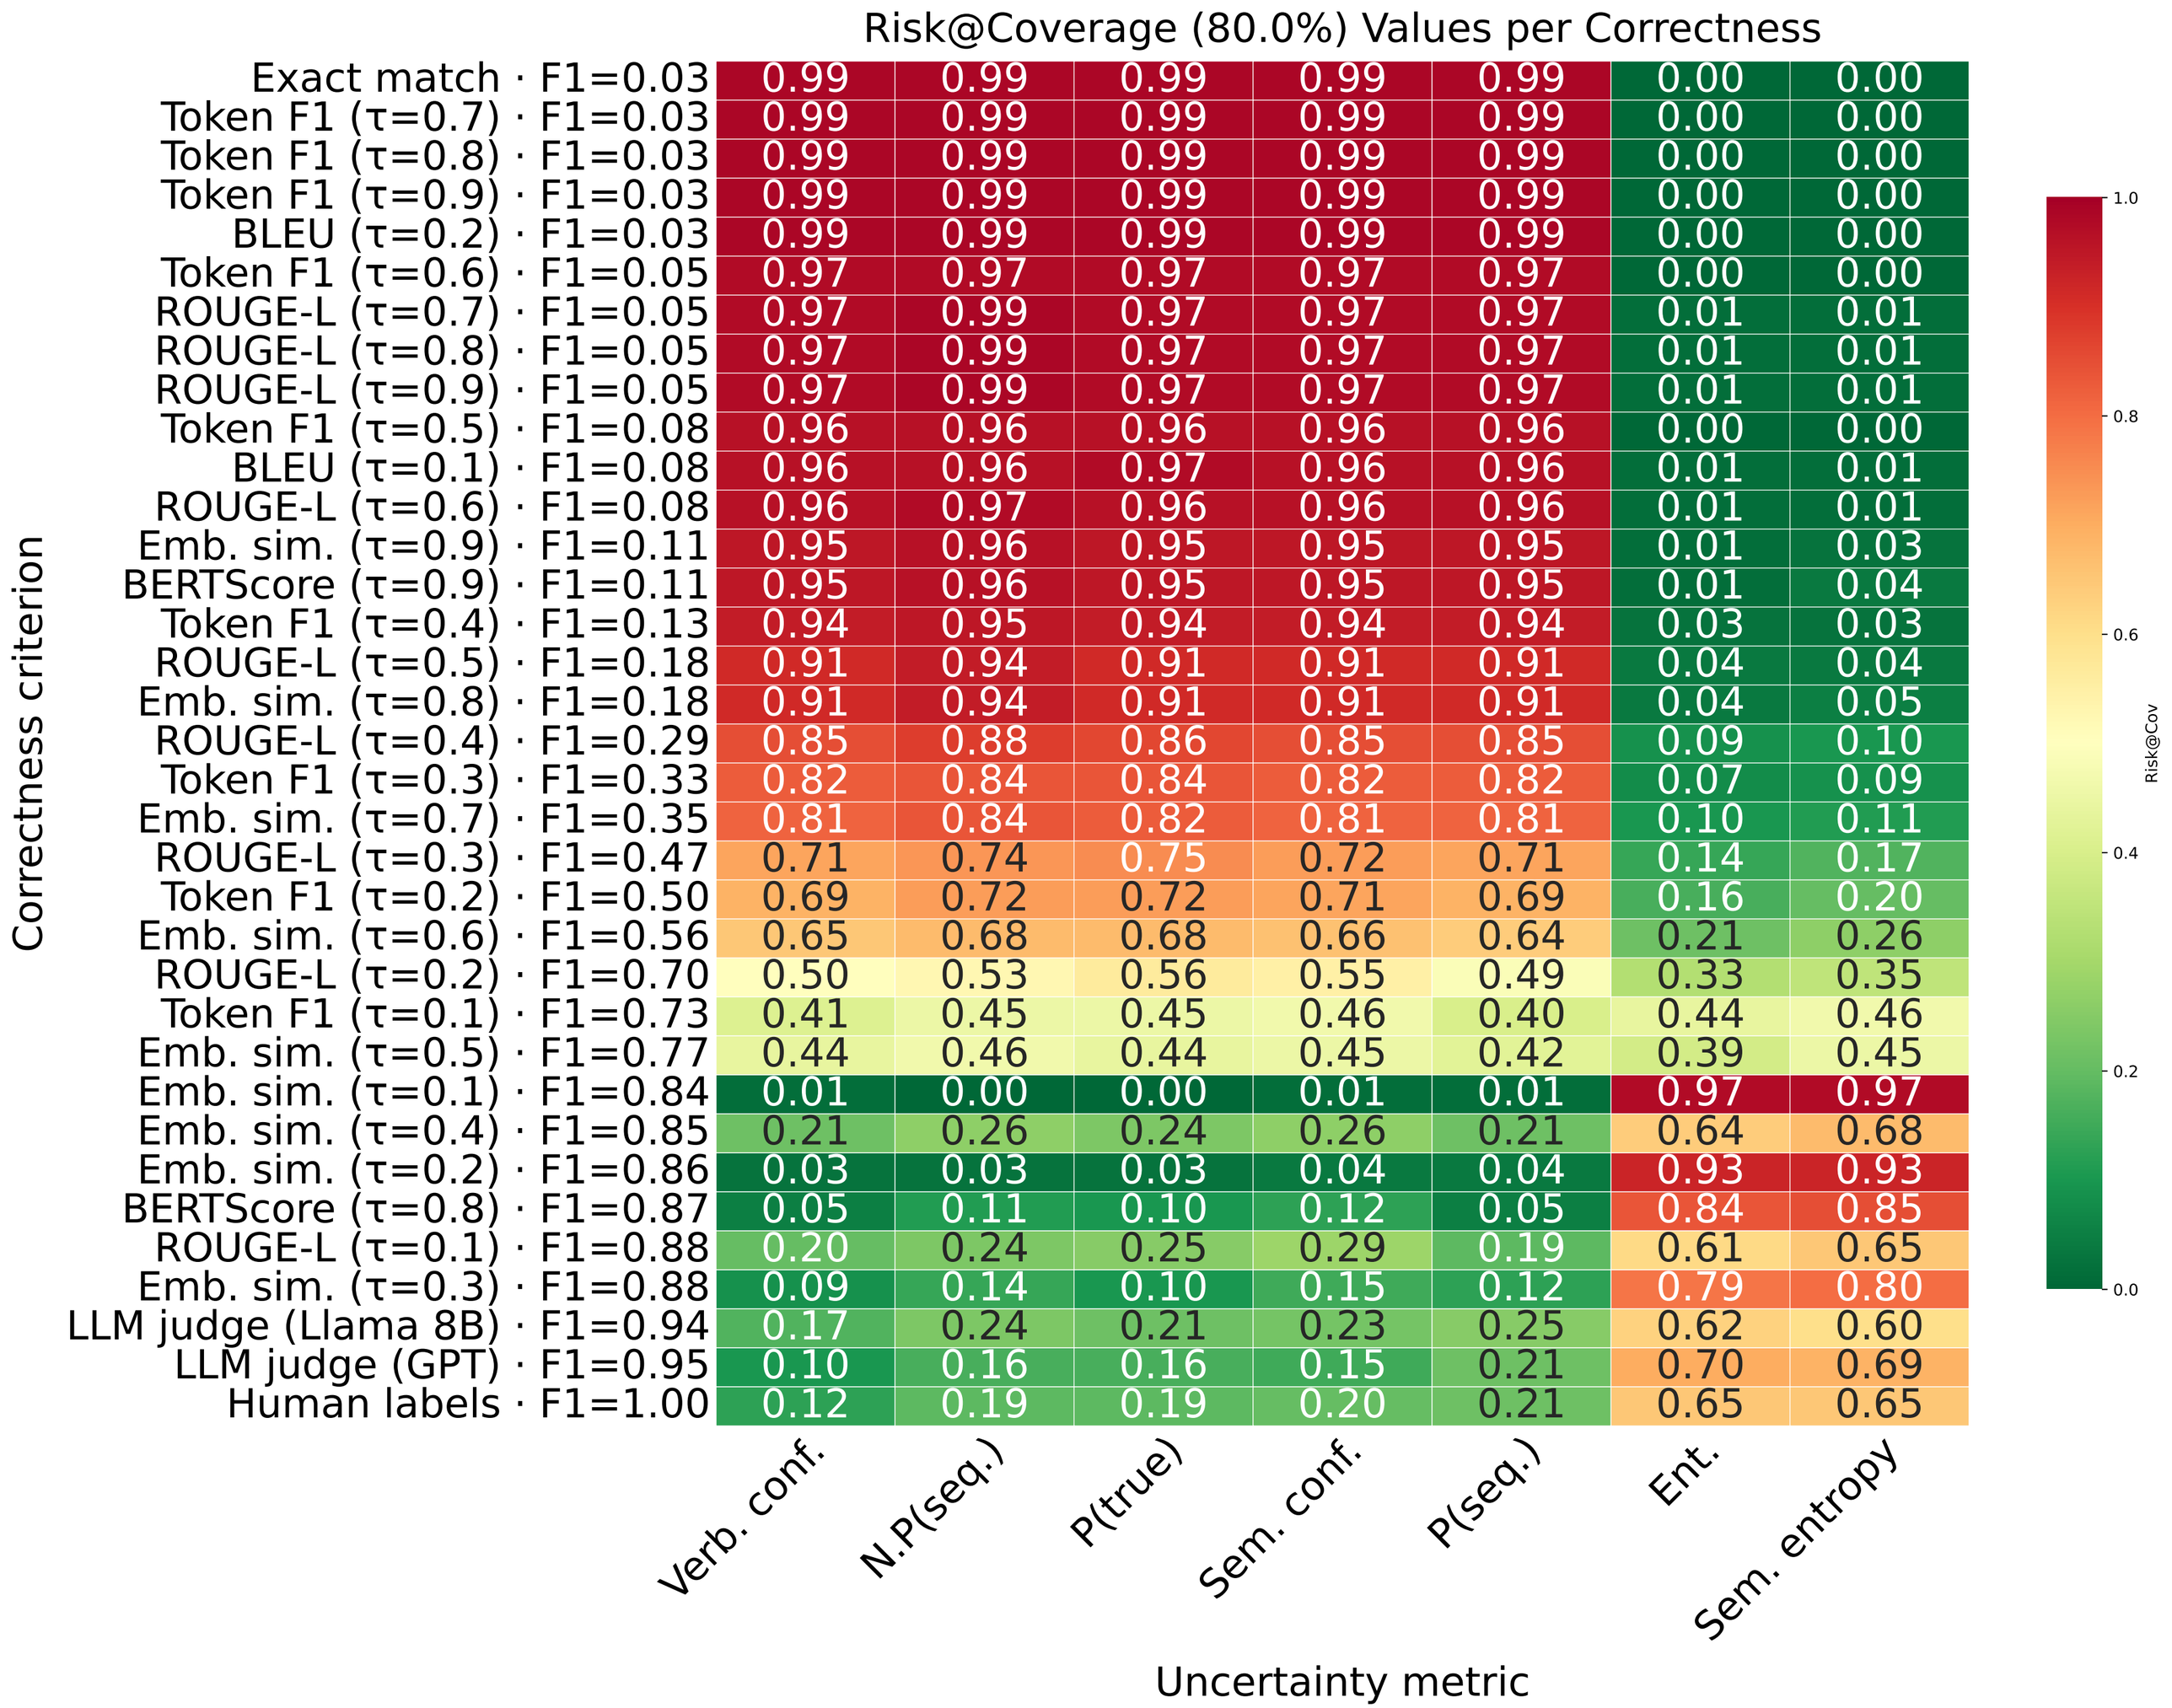
Risk@Coverage (80.0%) Values per Correctness
Correctness criterion
Uncertainty metric
Risk@Cov
Exact match · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.7) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.8) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.9) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
BLEU (τ=0.2) · F1=0.03 0.99 0.99 0.99 0.99 0.99 0.00 0.00
Token F1 (τ=0.6) · F1=0.05 0.97 0.97 0.97 0.97 0.97 0.00 0.00
ROUGE-L (τ=0.7) · F1=0.05 0.97 0.99 0.97 0.97 0.97 0.01 0.01
ROUGE-L (τ=0.8) · F1=0.05 0.97 0.99 0.97 0.97 0.97 0.01 0.01
ROUGE-L (τ=0.9) · F1=0.05 0.97 0.99 0.97 0.97 0.97 0.01 0.01
Token F1 (τ=0.5) · F1=0.08 0.96 0.96 0.96 0.96 0.96 0.00 0.00
BLEU (τ=0.1) · F1=0.08 0.96 0.96 0.97 0.96 0.96 0.01 0.01
ROUGE-L (τ=0.6) · F1=0.08 0.96 0.97 0.96 0.96 0.96 0.01 0.01
Emb. sim. (τ=0.9) · F1=0.11 0.95 0.96 0.95 0.95 0.95 0.01 0.03
BERTScore (τ=0.9) · F1=0.11 0.95 0.96 0.95 0.95 0.95 0.01 0.04
Token F1 (τ=0.4) · F1=0.13 0.94 0.95 0.94 0.94 0.94 0.03 0.03
ROUGE-L (τ=0.5) · F1=0.18 0.91 0.94 0.91 0.91 0.91 0.04 0.04
Emb. sim. (τ=0.8) · F1=0.18 0.91 0.94 0.91 0.91 0.91 0.04 0.05
ROUGE-L (τ=0.4) · F1=0.29 0.85 0.88 0.86 0.85 0.85 0.09 0.10
Token F1 (τ=0.3) · F1=0.33 0.82 0.84 0.84 0.82 0.82 0.07 0.09
Emb. sim. (τ=0.7) · F1=0.35 0.81 0.84 0.82 0.81 0.81 0.10 0.11
ROUGE-L (τ=0.3) · F1=0.47 0.71 0.74 0.75 0.72 0.71 0.14 0.17
Token F1 (τ=0.2) · F1=0.50 0.69 0.72 0.72 0.71 0.69 0.16 0.20
Emb. sim. (τ=0.6) · F1=0.56 0.65 0.68 0.68 0.66 0.64 0.21 0.26
ROUGE-L (τ=0.2) · F1=0.70 0.50 0.53 0.56 0.55 0.49 0.33 0.35
Token F1 (τ=0.1) · F1=0.73 0.41 0.45 0.45 0.46 0.40 0.44 0.46
Emb. sim. (τ=0.5) · F1=0.77 0.44 0.46 0.44 0.45 0.42 0.39 0.45
Emb. sim. (τ=0.1) · F1=0.84 0.01 0.00 0.00 0.01 0.01 0.97 0.97
Emb. sim. (τ=0.4) · F1=0.85 0.21 0.26 0.24 0.26 0.21 0.64 0.68
Emb. sim. (τ=0.2) · F1=0.86 0.03 0.03 0.03 0.04 0.04 0.93 0.93
BERTScore (τ=0.8) · F1=0.87 0.05 0.11 0.10 0.12 0.05 0.84 0.85
ROUGE-L (τ=0.1) · F1=0.88 0.20 0.24 0.25 0.29 0.19 0.61 0.65
Emb. sim. (τ=0.3) · F1=0.88 0.09 0.14 0.10 0.15 0.12 0.79 0.80
LLM judge (Llama 8B) · F1=0.94 0.17 0.24 0.21 0.23 0.25 0.62 0.60
LLM judge (GPT) · F1=0.95 0.10 0.16 0.16 0.15 0.21 0.70 0.69
Human labels · F1=1.00 0.12 0.19 0.19 0.20 0.21 0.65 0.65
Verb. conf.
N.P(seq.)
P(true)
Sem. conf.
P(seq.)
Ent.
Sem. entropy
1.0
0.8
0.6
0.4
0.2
0.0