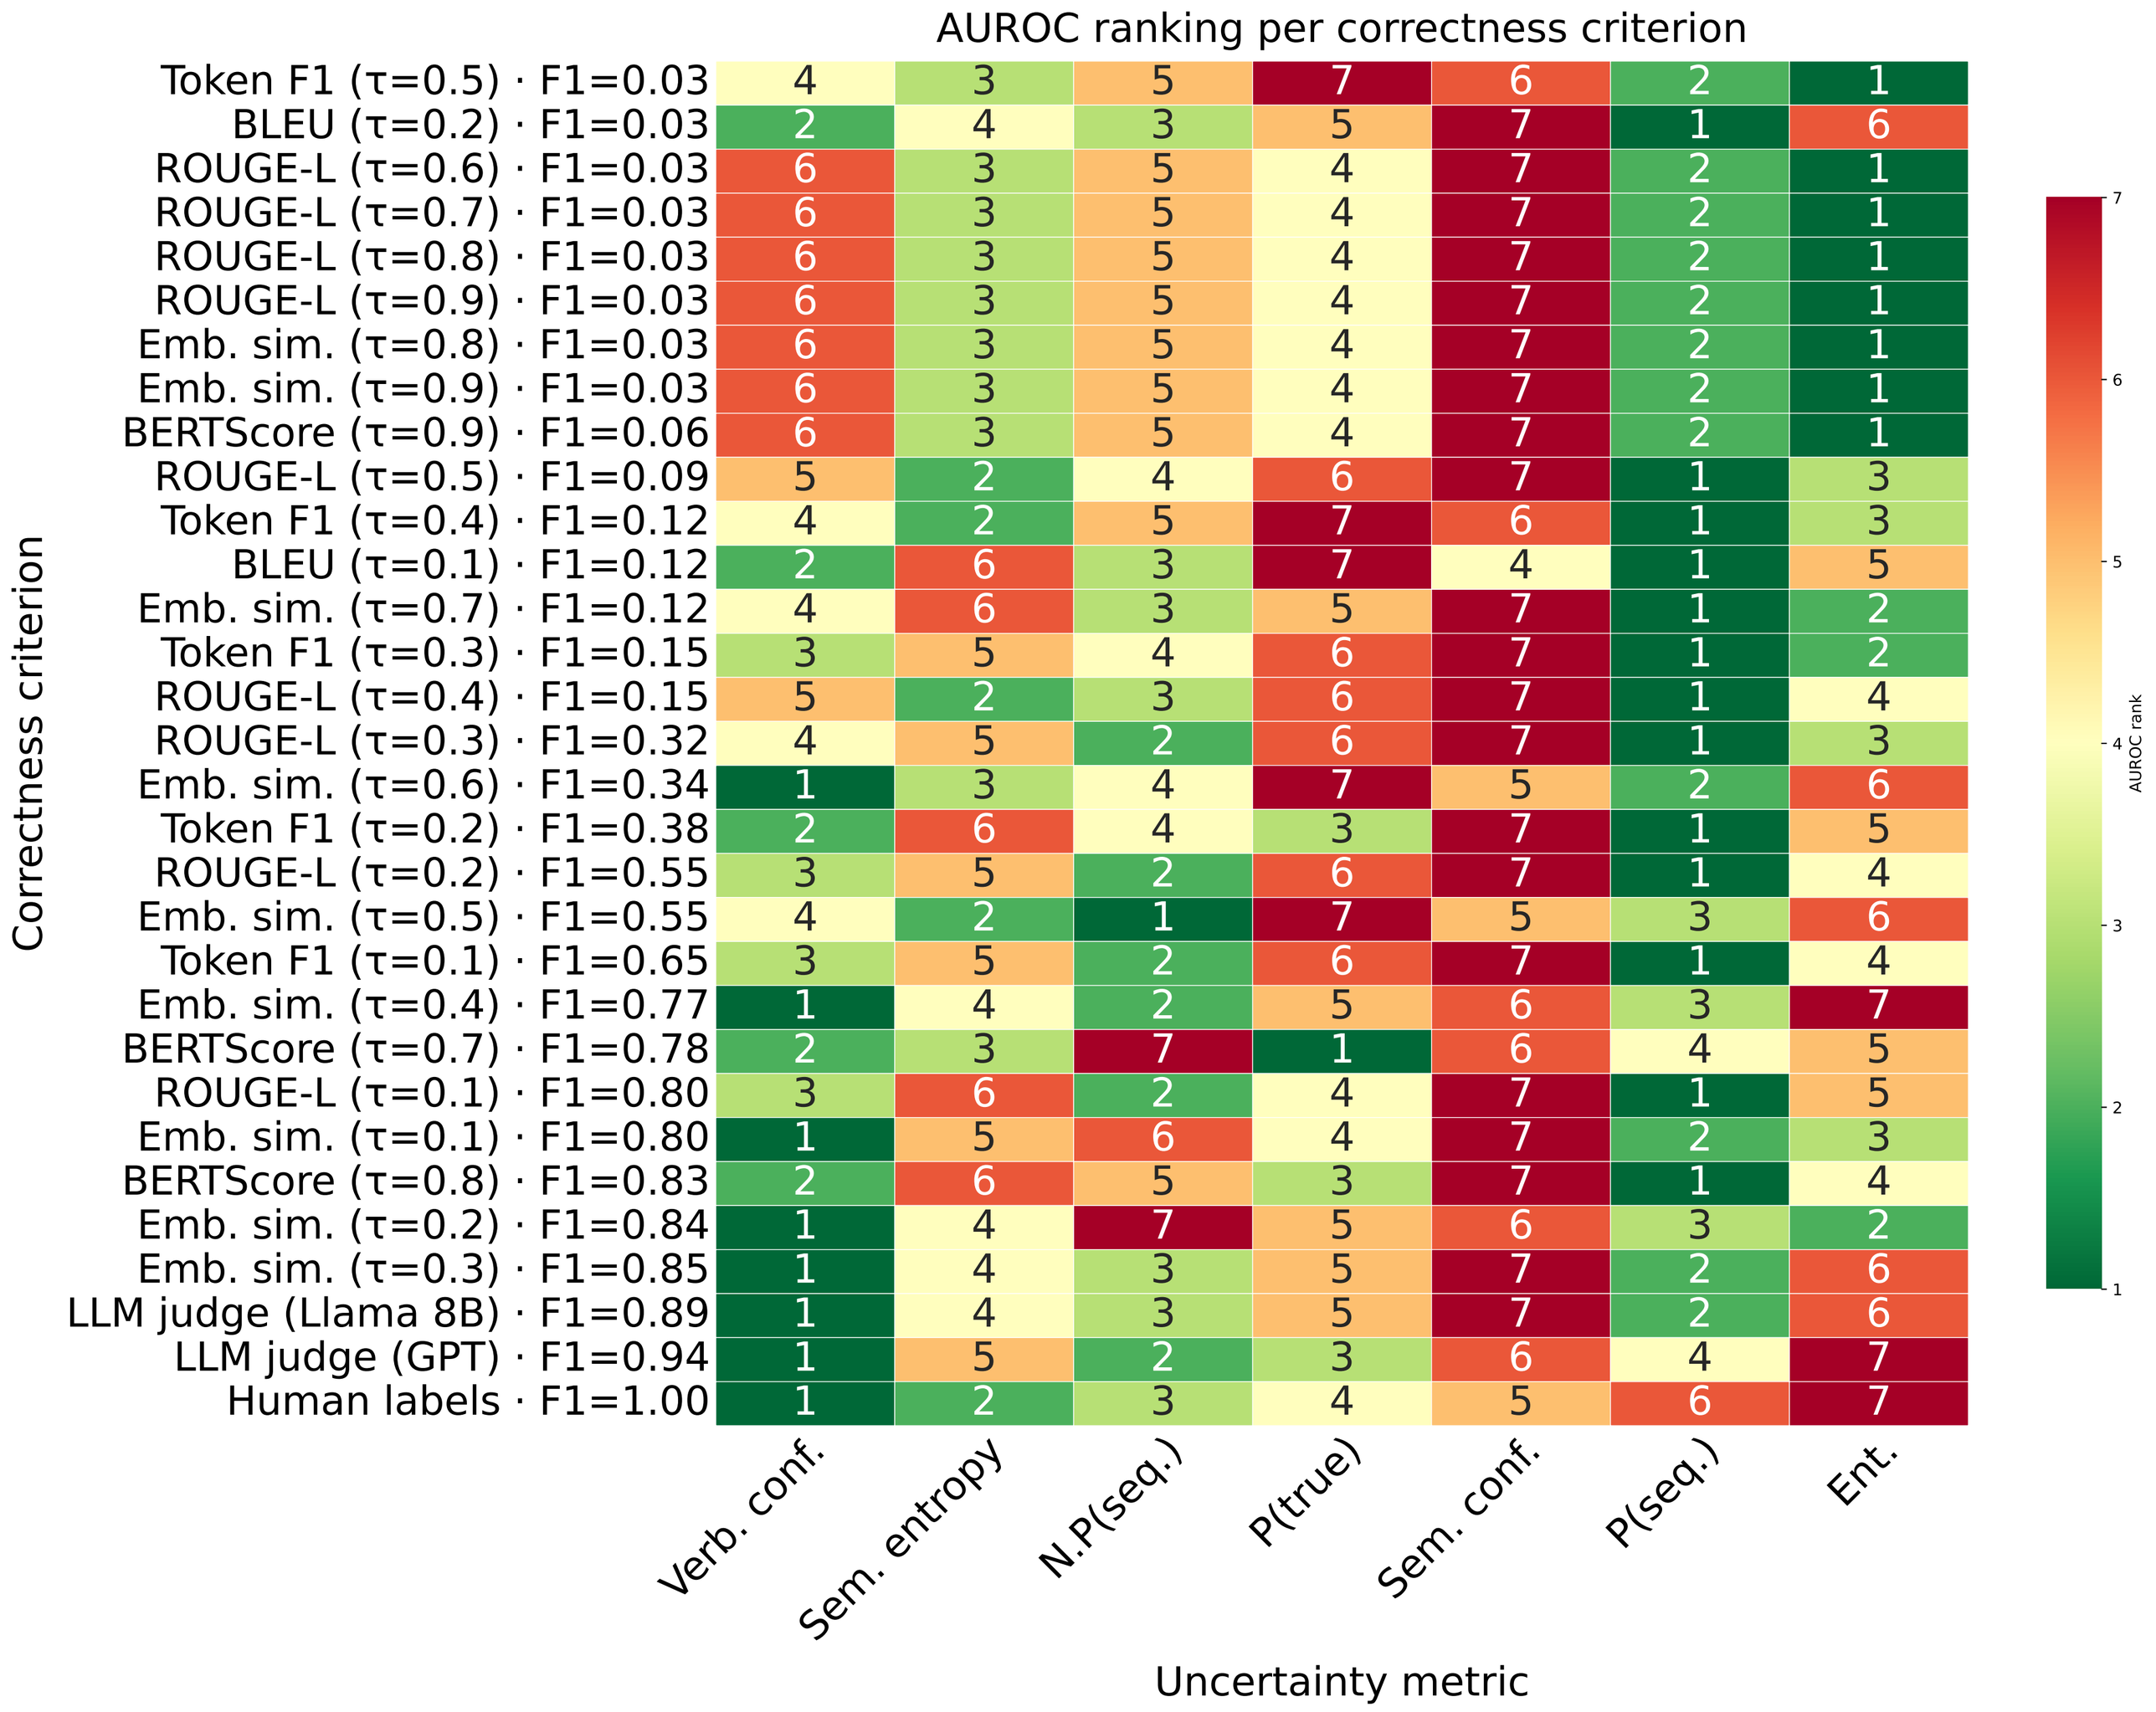
AUROC ranking per correctness criterion
Correctness criterion
Uncertainty metric
AUROC rank
Verb. conf.
Sem. entropy
N.P(seq.)
P(true)
Sem. conf.
P(seq.)
Ent.
Token F1 (τ=0.5) · F1=0.03 4 3 5 7 6 2 1
BLEU (τ=0.2) · F1=0.03 2 4 3 5 7 1 6
ROUGE-L (τ=0.6) · F1=0.03 6 3 5 4 7 2 1
ROUGE-L (τ=0.7) · F1=0.03 6 3 5 4 7 2 1
ROUGE-L (τ=0.8) · F1=0.03 6 3 5 4 7 2 1
ROUGE-L (τ=0.9) · F1=0.03 6 3 5 4 7 2 1
Emb. sim. (τ=0.8) · F1=0.03 6 3 5 4 7 2 1
Emb. sim. (τ=0.9) · F1=0.03 6 3 5 4 7 2 1
BERTScore (τ=0.9) · F1=0.06 6 3 5 4 7 2 1
ROUGE-L (τ=0.5) · F1=0.09 5 2 4 6 7 1 3
Token F1 (τ=0.4) · F1=0.12 4 2 5 7 6 1 3
BLEU (τ=0.1) · F1=0.12 2 6 3 7 4 1 5
Emb. sim. (τ=0.7) · F1=0.12 4 6 3 5 7 1 2
Token F1 (τ=0.3) · F1=0.15 3 5 4 6 7 1 2
ROUGE-L (τ=0.4) · F1=0.15 5 2 3 6 7 1 4
ROUGE-L (τ=0.3) · F1=0.32 4 5 2 6 7 1 3
Emb. sim. (τ=0.6) · F1=0.34 1 3 4 7 5 2 6
Token F1 (τ=0.2) · F1=0.38 2 6 4 3 7 1 5
ROUGE-L (τ=0.2) · F1=0.55 3 5 2 6 7 1 4
Emb. sim. (τ=0.5) · F1=0.55 4 2 1 7 5 3 6
Token F1 (τ=0.1) · F1=0.65 3 5 2 6 7 1 4
Emb. sim. (τ=0.4) · F1=0.77 1 4 2 5 6 3 7
BERTScore (τ=0.7) · F1=0.78 2 3 7 1 6 4 5
ROUGE-L (τ=0.1) · F1=0.80 3 6 2 4 7 1 5
Emb. sim. (τ=0.1) · F1=0.80 1 5 6 4 7 2 3
BERTScore (τ=0.8) · F1=0.83 2 6 5 3 7 1 4
Emb. sim. (τ=0.2) · F1=0.84 1 4 7 5 6 3 2
Emb. sim. (τ=0.3) · F1=0.85 1 4 3 5 7 2 6
LLM judge (Llama 8B) · F1=0.89 1 4 3 5 7 2 6
LLM judge (GPT) · F1=0.94 1 5 2 3 6 4 7
Human labels · F1=1.00 1 2 3 4 5 6 7
7
6
5
4
3
2
1