

AUROC ranking per correctness criterion

Correctness criterion

Exact match · F1=0.03	2	7	4	5	1	3	6
Token F1 ($\tau=0.7$) · F1=0.03	2	7	4	5	1	3	6
Token F1 ($\tau=0.8$) · F1=0.03	2	7	4	5	1	3	6
Token F1 ($\tau=0.9$) · F1=0.03	2	7	4	5	1	3	6
BLEU ($\tau=0.2$) · F1=0.03	2	7	4	5	1	3	6
Token F1 ($\tau=0.6$) · F1=0.06	2	5	4	6	1	3	7
BLEU ($\tau=0.1$) · F1=0.06	2	4	6	5	1	3	7
ROUGE-L ($\tau=0.7$) · F1=0.06	2	7	4	5	1	3	6
ROUGE-L ($\tau=0.8$) · F1=0.06	2	7	4	5	1	3	6
ROUGE-L ($\tau=0.9$) · F1=0.06	2	7	4	5	1	3	6
BERTScore ($\tau=0.9$) · F1=0.06	2	7	4	5	1	3	6
Token F1 ($\tau=0.5$) · F1=0.10	2	4	6	5	1	3	7
Emb. sim. ($\tau=0.9$) · F1=0.10	2	7	4	5	1	3	6
Token F1 ($\tau=0.4$) · F1=0.12	2	7	5	4	1	3	6
ROUGE-L ($\tau=0.6$) · F1=0.12	2	7	3	5	1	4	6
ROUGE-L ($\tau=0.5$) · F1=0.18	2	7	3	5	1	4	6
Emb. sim. ($\tau=0.8$) · F1=0.24	3	7	2	6	1	4	5
Token F1 ($\tau=0.3$) · F1=0.29	2	4	5	7	1	3	6
ROUGE-L ($\tau=0.4$) · F1=0.33	1	7	3	6	2	4	5
Emb. sim. ($\tau=0.7$) · F1=0.38	2	7	3	6	1	4	5
Token F1 ($\tau=0.2$) · F1=0.55	1	5	3	7	2	4	6
ROUGE-L ($\tau=0.3$) · F1=0.55	1	7	4	6	2	3	5
Emb. sim. ($\tau=0.6$) · F1=0.62	2	6	1	3	4	5	7
Token F1 ($\tau=0.1$) · F1=0.75	1	5	2	4	3	6	7
ROUGE-L ($\tau=0.2$) · F1=0.76	1	2	5	4	3	6	7
Emb. sim. ($\tau=0.1$) · F1=0.77	3	4	1	5	6	2	7
BERTScore ($\tau=0.8$) · F1=0.78	3	5	1	2	4	6	7
Emb. sim. ($\tau=0.5$) · F1=0.79	3	5	1	2	4	6	7
Emb. sim. ($\tau=0.2$) · F1=0.81	3	5	1	2	6	4	7
Emb. sim. ($\tau=0.4$) · F1=0.85	3	5	2	1	4	6	7
Emb. sim. ($\tau=0.3$) · F1=0.86	3	4	2	1	6	5	7
ROUGE-L ($\tau=0.1$) · F1=0.88	1	5	2	3	4	6	7
LLM judge (Llama 8B) · F1=0.92	1	4	2	3	5	6	7
LLM judge (GPT) · F1=0.94	2	4	3	1	5	6	7
Human labels · F1=1.00	1	2	3	4	5	6	7

P(seq.)

N.P(seq.)

P(true)

Verb. conf.

Ent.

Sem. entropy

Sem. conf.

Uncertainty metric

AUROC rank