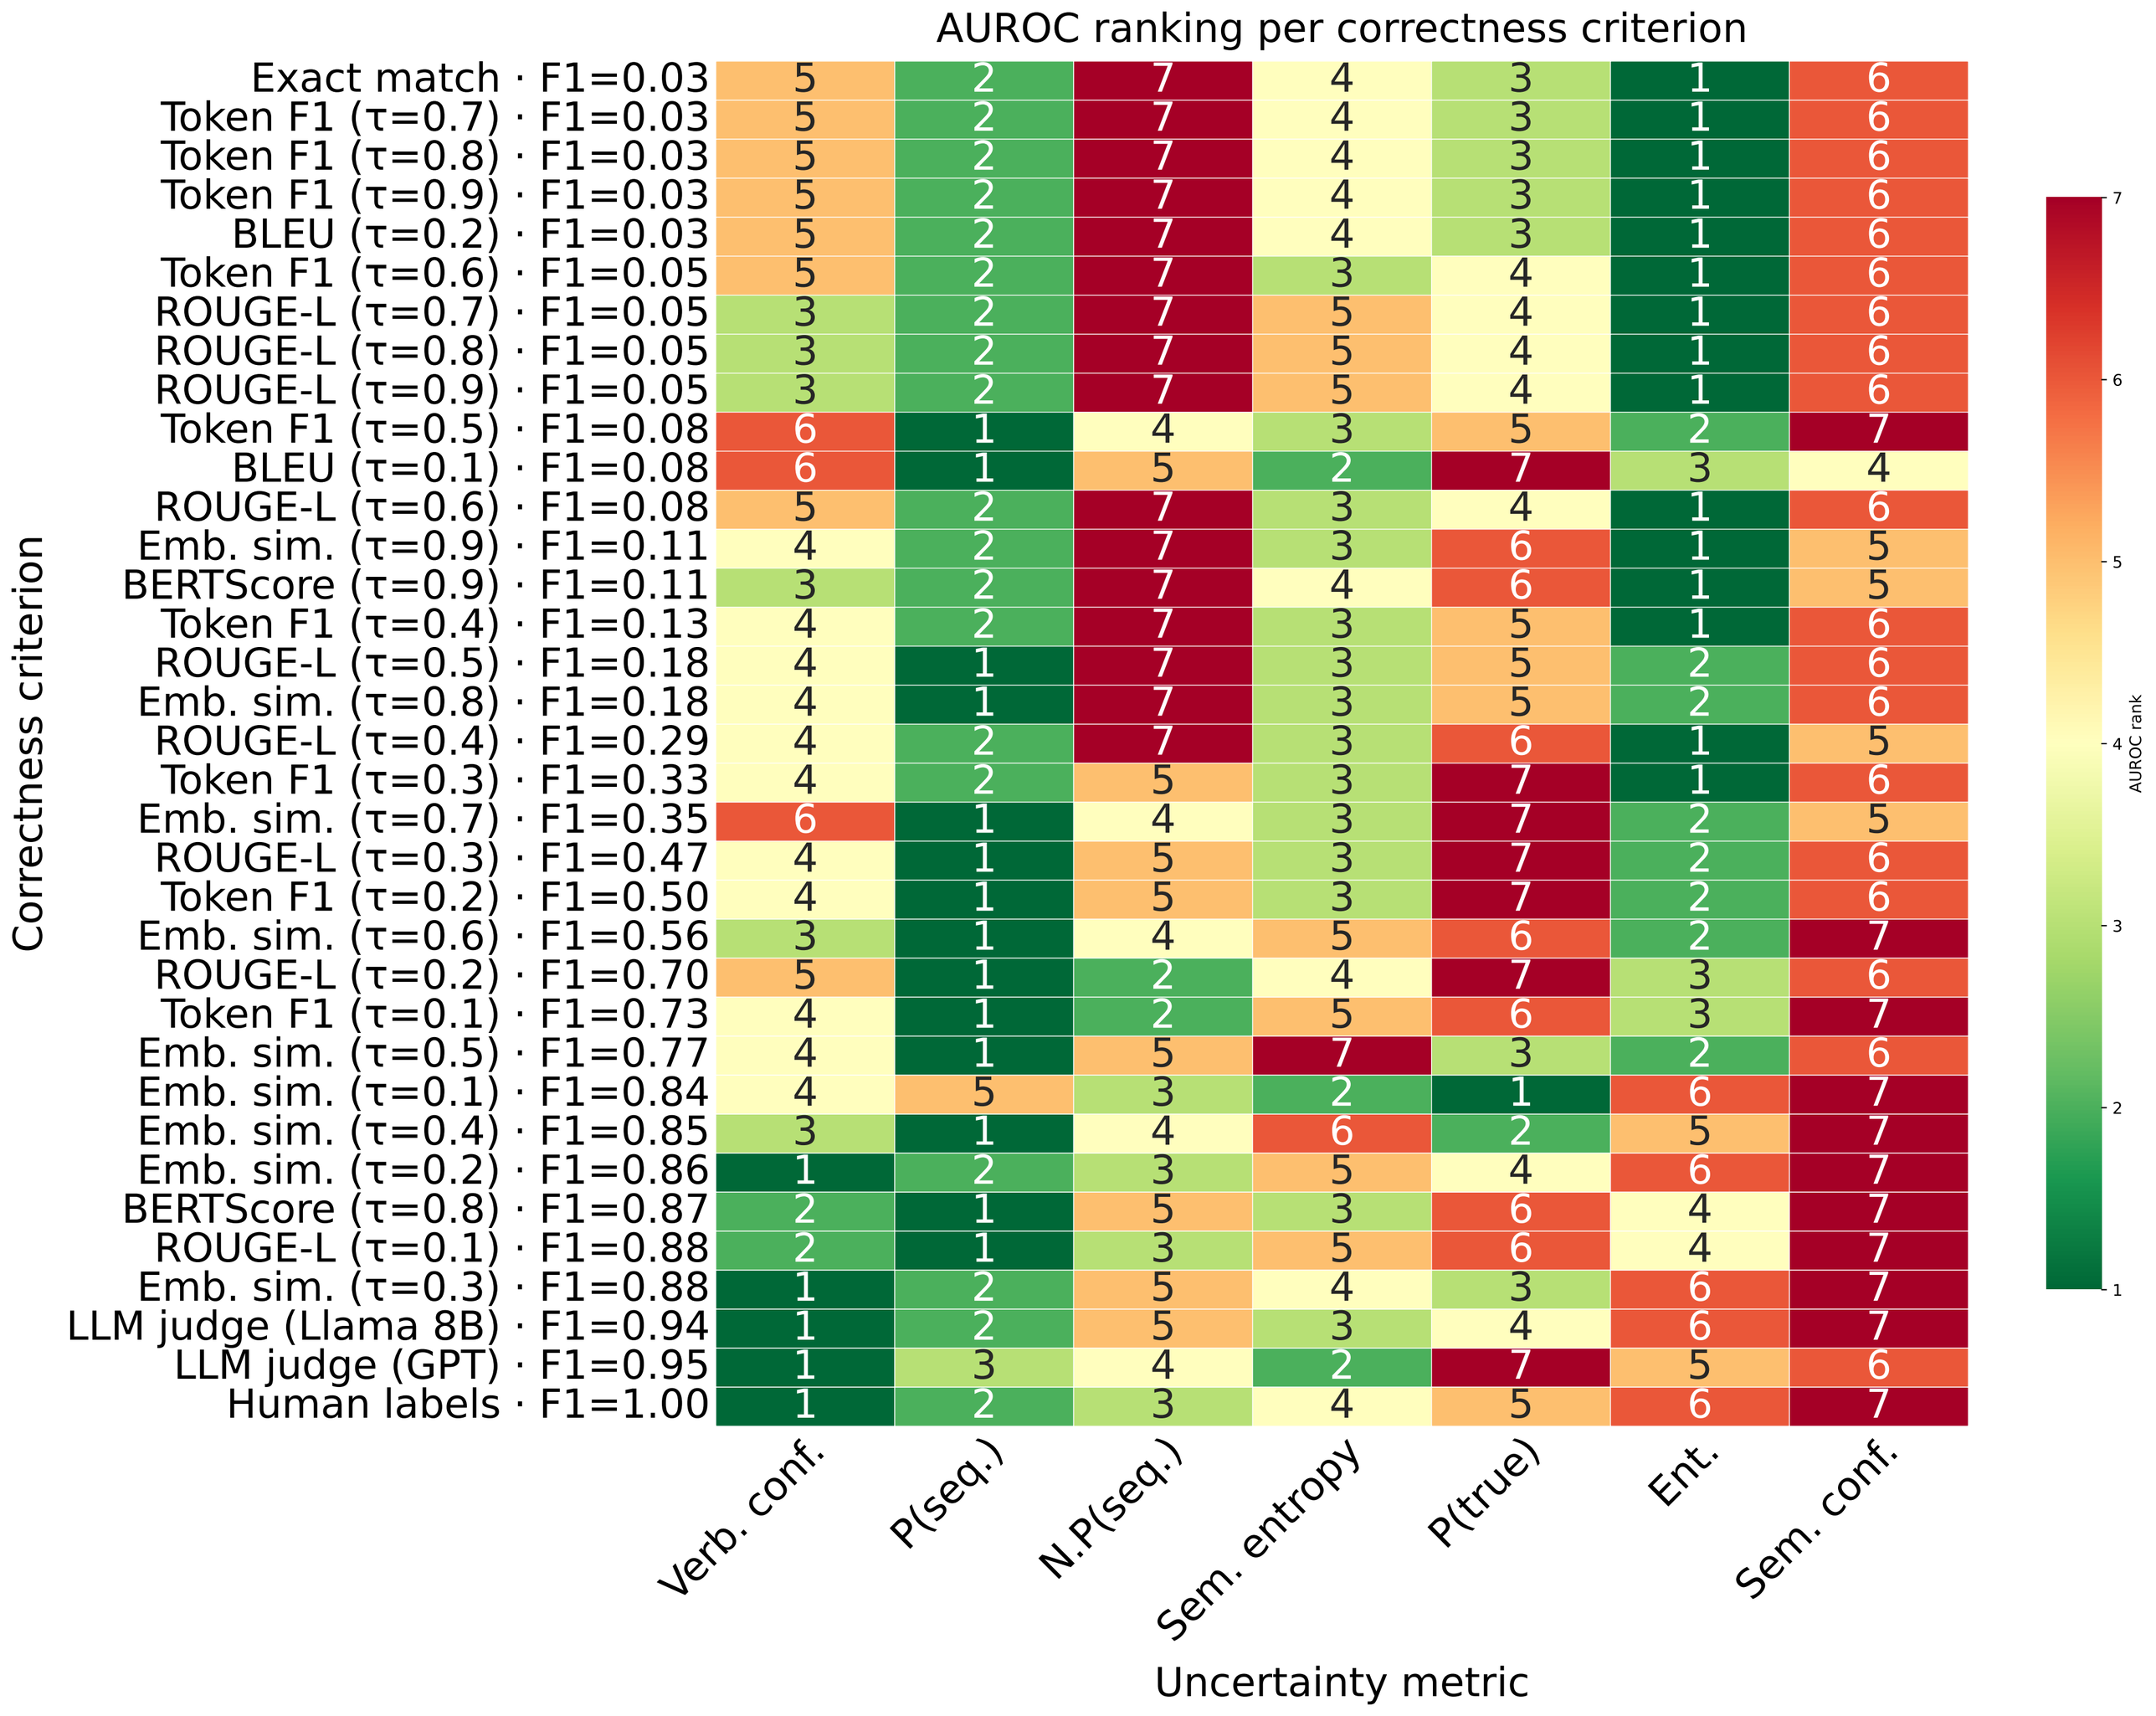
AUROC ranking per correctness criterion
Correctness criterion
Uncertainty metric
AUROC rank
Exact match · F1=0.03 5 2 7 4 3 1 6
Token F1 (τ=0.7) · F1=0.03 5 2 7 4 3 1 6
Token F1 (τ=0.8) · F1=0.03 5 2 7 4 3 1 6
Token F1 (τ=0.9) · F1=0.03 5 2 7 4 3 1 6
BLEU (τ=0.2) · F1=0.03 5 2 7 4 3 1 6
Token F1 (τ=0.6) · F1=0.05 5 2 7 3 4 1 6
ROUGE-L (τ=0.7) · F1=0.05 3 2 7 5 4 1 6
ROUGE-L (τ=0.8) · F1=0.05 3 2 7 5 4 1 6
ROUGE-L (τ=0.9) · F1=0.05 3 2 7 5 4 1 6
Token F1 (τ=0.5) · F1=0.08 6 1 4 3 5 2 7
BLEU (τ=0.1) · F1=0.08 6 1 5 2 7 3 4
ROUGE-L (τ=0.6) · F1=0.08 5 2 7 3 4 1 6
Emb. sim. (τ=0.9) · F1=0.11 4 2 7 3 6 1 5
BERTScore (τ=0.9) · F1=0.11 3 2 7 4 6 1 5
Token F1 (τ=0.4) · F1=0.13 4 2 7 3 5 1 6
ROUGE-L (τ=0.5) · F1=0.18 4 1 7 3 5 2 6
Emb. sim. (τ=0.8) · F1=0.18 4 1 7 3 5 2 6
ROUGE-L (τ=0.4) · F1=0.29 4 2 7 3 6 1 5
Token F1 (τ=0.3) · F1=0.33 4 2 5 3 7 1 6
Emb. sim. (τ=0.7) · F1=0.35 6 1 4 3 7 2 5
ROUGE-L (τ=0.3) · F1=0.47 4 1 5 3 7 2 6
Token F1 (τ=0.2) · F1=0.50 4 1 5 3 7 2 6
Emb. sim. (τ=0.6) · F1=0.56 3 1 4 5 6 2 7
ROUGE-L (τ=0.2) · F1=0.70 5 1 2 4 7 3 6
Token F1 (τ=0.1) · F1=0.73 4 1 2 5 6 3 7
Emb. sim. (τ=0.5) · F1=0.77 4 1 5 7 3 2 6
Emb. sim. (τ=0.1) · F1=0.84 4 5 3 2 1 6 7
Emb. sim. (τ=0.4) · F1=0.85 3 1 4 6 2 5 7
Emb. sim. (τ=0.2) · F1=0.86 1 2 3 5 4 6 7
BERTScore (τ=0.8) · F1=0.87 2 1 5 3 6 4 7
ROUGE-L (τ=0.1) · F1=0.88 2 1 3 5 6 4 7
Emb. sim. (τ=0.3) · F1=0.88 1 2 5 4 3 6 7
LLM judge (Llama 8B) · F1=0.94 1 2 5 3 4 6 7
LLM judge (GPT) · F1=0.95 1 3 4 2 7 5 6
Human labels · F1=1.00 1 2 3 4 5 6 7
Verb. conf.
P(seq.)
N.P(seq.)
Sem. entropy
P(true)
Ent.
Sem. conf.
7
6
5
4
3
2
1